Demostración de la no negatividad de la divergencia KL

Arturo Olivares Martos

29 de julio de 2026

Definición 1. Dadas dos funciones de densidad de probabilidad $p(x)$ y $q(x)$ definidas sobre un mismo espacio de probabilidad, donde $p(x), q(x) > 0$ para todo x, la divergencia de Kullback-Leibler (KL) de q respecto a p se define como:

$$\mathcal{D}_{\mathrm{KL}}(p||q) = \int p(x) \log\left(\frac{p(x)}{q(x)}\right) dx = \mathbb{E}_p\left[\log\left(\frac{p(X)}{q(X)}\right)\right] \tag{1}$$

Nuestro objetivo es demostrar que la divergencia KL es siempre no negativa, es decir, $\mathcal{D}_{\mathrm{KL}}(p||q) \geqslant 0$ para todas las funciones de densidad de probabilidad p y q. Para ello, hemos de demostrar en primer lugar la desigualdad de Jensen.

Teorema 1 (Desigualdad de Jensen)**.** *Sea X una variable aleatoria y $f : \mathbb{R} \to \mathbb{R}$ una función convexa. Entonces:*

$$\mathbb{E}[f(X)] \geqslant f(\mathbb{E}[X]) \tag{2}$$

Demostración. Sea X una variable aleatoria y f una función convexa. Por definición de convexidad, fijado $x_0 \in \mathbb{R}$, existe una constante $c \in \mathbb{R}$ con:

$$f(x) \geqslant f(x_0) + c(x - x_0) \qquad \forall x \in \mathbb{R}$$

Evaluamos la desigualdad anterior tomando $x_0 = \mathbb{E}[X]$, por lo que $\exists c \in \mathbb{R}$ tal que:

$$f(x) \geqslant f(\mathbb{E}[X]) + c(x - \mathbb{E}[X]) \qquad \forall x \in \mathbb{R}$$

Tomamos ahora la esperanza de ambos lados de la desigualdad y, tras aplicar la linealidad de la esperanza, obtenemos:

$$\mathbb{E}[f(X)] \geqslant \mathbb{E}\left[f(\mathbb{E}[X]) + c(X - \mathbb{E}[X])\right] = f(\mathbb{E}[X]) + c(\mathbb{E}[X] - \mathbb{E}[X]) = f(\mathbb{E}[X])$$

□

Una vez demostrada la desigualdad de Jensen, podemos proceder a demostrar la no negatividad de la divergencia KL.

Teorema 2 (No negatividad de la divergencia KL)**.** *Sea $p(x)$ y $q(x)$ dos funciones de densidad de probabilidad definidas sobre un mismo espacio de probabilidad. Entonces:*

$$\mathcal{D}_{KL}(p||q) \geqslant 0 \tag{3}$$

Demostración. Puesto que el logaritmo no es una función convexa, consideremos la función $f(x) = -\log(x)$, que sí lo es en $\mathbb{R}^+$. Entonces, podemos reescribir la divergencia KL como:

$$\mathcal{D}_{\mathrm{KL}}(p||q) = \mathbb{E}_p\left[\log\left(\frac{p(X)}{q(X)}\right)\right] = \mathbb{E}_p\left[-\log\left(\frac{q(X)}{p(X)}\right)\right]$$

Puesto que $p(x)$ y $q(x)$ son funciones de densidad de probabilidad y no se anulan, tenemos que:

$$\frac{q(x)}{p(x)} > 0 \quad \forall x \in \mathbb{R}$$

Por tanto, podemos aplicar la desigualdad de Jensen a la variable aleatoria ${}^{q(X)}/_{p(X)}$ y a la función convexa $f(x) = -\log(x)$:

$$\mathcal{D}_{\mathrm{KL}}(p||q) = \mathbb{E}_p\left[-\log\left(\frac{q(X)}{p(X)}\right)\right] \geqslant -\log\left(\mathbb{E}_p\left[\frac{q(X)}{p(X)}\right]\right)$$

Calculemos ahora la esperanza de ${}^{q(X)}/_{p(X)}$ bajo la distribución p:

$$\mathbb{E}_p\left[\frac{q(X)}{p(X)}\right] = \int_{\mathbb{R}} p(x)\frac{q(x)}{p(x)}dx = \int_{\mathbb{R}} q(x)dx \overset{(*)}{=} 1$$

donde en $(*)$ hemos utilizado el hecho de que $q(x)$ es una función de densidad de probabilidad, por lo que su integral sobre todo el espacio es igual a 1. Por tanto, tenemos que:

$$\mathcal{D}_{\mathrm{KL}}(p||q) \geqslant -\log(1) = 0$$

□