Capítulo 1. Deep Generative Models

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

24 de junio de 2026



Índice

1 Objetivo de un DGM

2 Función de pérdida



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$

- Las combinaciones reales de los datos tendrán alta probabilidad, mientras que las combinaciones irreales (ruido, etc.) tendrán probabilidad prácticamente nula.



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$

- Las combinaciones reales de los datos tendrán alta probabilidad, mientras que las combinaciones irreales (ruido, etc.) tendrán probabilidad prácticamente nula.
- Esta distribución es *desconocida* (tan solo tenemos acceso a una muestra de datos).



Distribución del modelo

El DGM emplea una DNN con parámetros ϕ para obtener una distribución de probabilidad

$$p_\phi$$

de manera que $p_\phi \approx p_{\text{data}}$.



Distribución del modelo

El DGM emplea una DNN con parámetros ϕ para obtener una distribución de probabilidad

$$p_\phi$$

de manera que $p_\phi \approx p_{\text{data}}$.

Objetivo de un DGM

Aprender la distribución p_{data} a partir de una muestra de datos, para poder generar nuevas muestras que sigan la misma distribución.



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:

- Generación realista (Test de Lovelance)



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:

- Generación realista (Test de Lovelance)
- Generación controlada



Índice

1 Objetivo de un DGM

2 Función de pérdida



Función de pérdida

Para entrenar la DNN, necesitamos una función de pérdida que mida la diferencia entre p_ϕ y p_{data}.

$$\mathcal{D}(p_{\text{data}}, p_\phi)$$

Entrenar la DNN consiste en obtener los parámetros ϕ que minimicen la función de pérdida.



Función de pérdida

Para entrenar la DNN, necesitamos una función de pérdida que mida la diferencia entre p_ϕ y p_{data}.

$$\mathcal{D}(p_{\text{data}}, p_\phi)$$

Entrenar la DNN consiste en obtener los parámetros ϕ que minimicen la función de pérdida. Hay varias funciones de pérdida que se pueden emplear.



Divergencia KL

Divergencia KL

La divergencia KL entre dos distribuciones de probabilidad p_{data} y p_ϕ es:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}||p_\phi) := \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\phi(x)} dx$$



Divergencia KL

Divergencia KL

La divergencia KL entre dos distribuciones de probabilidad p_{data} y p_ϕ es:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}||p_\phi) := \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\phi(x)} dx$$

Emplear la divergencia KL fuerza la cobertura del modelo; es decir, toda muestra x con $p_{\text{data}}(x) > 0$ debe tener $p_\phi(x) > 0$ (para no dividir entre cero).

$$p_{\text{data}}(x) > 0 \implies p_\phi(x) > 0 \qquad \forall x$$



Divergencia KL

Propiedades

- No es simétrica: $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}||p_\phi) \neq \mathcal{D}_{\mathrm{KL}}(p_\phi||p_{\mathrm{data}})$
- Es no negativa: $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}||p_\phi) \geq 0$
- Es cero si y solo si $p_{\mathrm{data}} = p_\phi$ c.p.d.

