Capítulo 1. Deep Generative Models

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

25 de junio de 2026



Índice

1. Objetivo de un DGM
2. Función de pérdida
3. Camino a obtener p_ϕ



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$

- Las combinaciones reales de los datos tendrán alta probabilidad, mientras que las combinaciones irreales (ruido, etc.) tendrán probabilidad prácticamente nula.



Distribución de los datos

Los datos de alta dimensionalidad con los que trabajemos siguien una distribución de probabilidad:

$$p_{\text{data}}$$

- Las combinaciones reales de los datos tendrán alta probabilidad, mientras que las combinaciones irreales (ruido, etc.) tendrán probabilidad prácticamente nula.
- Esta distribución es *desconocida* (tan solo tenemos acceso a una muestra de datos).



Distribución del modelo

El DGM emplea una DNN con parámetros ϕ para obtener una distribución de probabilidad

$$p_\phi$$

de manera que $p_\phi \approx p_{\text{data}}$.



Distribución del modelo

El DGM emplea una DNN con parámetros ϕ para obtener una distribución de probabilidad

$$p_\phi$$

de manera que $p_\phi \approx p_{\text{data}}$.

Objetivo de un DGM

Aprender la distribución p_{data} a partir de una muestra de datos, para poder generar nuevas muestras que sigan la misma distribución.



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:

- Generación realista (Test de Lovelance)



Generación de nuevas muestras

Una vez aprendido el modelo, podemos generar nuevas muestras de datos siguiendo la distribución p_ϕ:

$$x \sim p_\phi \approx p_{\text{data}}$$

Esta generación debe cumplir:

- Generación realista (Test de Lovelance)
- Generación controlada



Índice

1 Objetivo de un DGM

2 Función de pérdida

3 Camino a obtener p_ϕ



Función de pérdida

Divergencia

Una divergencia entre dos distribuciones de probabilidad p_{data} y p_ϕ es una función $\mathcal{D}(p_{\text{data}}, p_\phi)$ que cumple:

- No negatividad: $\mathcal{D}(p_{\text{data}}, p_\phi) \geq 0$
- Identidad: $\mathcal{D}(p_{\text{data}}, p_\phi) = 0 \iff p_{\text{data}} = p_\phi$ c.p.d.



Función de pérdida

Divergencia

Una divergencia entre dos distribuciones de probabilidad p_{data} y p_ϕ es una función $\mathcal{D}(p_{\text{data}}, p_\phi)$ que cumple:

- No negatividad: $\mathcal{D}(p_{\text{data}}, p_\phi) \geq 0$
- Identidad: $\mathcal{D}(p_{\text{data}}, p_\phi) = 0 \iff p_{\text{data}} = p_\phi$ c.p.d.

Entrenar la DNN consiste en obtener los parámetros ϕ que minimicen la función de pérdida. Hay varias funciones de pérdida que se pueden emplear.



Divergencia KL

Divergencia KL Directa

La divergencia KL directa entre dos distribuciones de probabilidad p_{data} y p_ϕ es:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}||p_\phi) := \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\phi(x)} dx$$

donde se ha tomado la primera distribución p_{data} como referencia.



Divergencia KL

Divergencia KL Directa

La divergencia KL directa entre dos distribuciones de probabilidad p_{data} y p_ϕ es:

$$\mathcal{D}_{\text{KL}}(p_{\text{data}}||p_\phi) := \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\phi(x)} dx$$

donde se ha tomado la primera distribución p_{data} como referencia.

Emplear la divergencia KL fuerza la cobertura del modelo; es decir, toda muestra x con $p_{\text{data}}(x) > 0$ debe tener $p_\phi(x) > 0$ (para no dividir entre cero).

$$p_{\text{data}}(x) > 0 \implies p_\phi(x) > 0 \qquad \forall x$$



Divergencia KL

Puesto que no conocemos la distribución p_{data}, no podemos calcular de forma directa la divergencia KL.

$$\begin{aligned}
\mathcal{D}_{\text{KL}}(p_{\text{data}}||p_\phi) &:= \int p_{\text{data}}(x) \log \frac{p_{\text{data}}(x)}{p_\phi(x)} dx \\
&= \mathbb{E}_{x\sim p_{\text{data}}} \left[\log \frac{p_{\text{data}}(x)}{p_\phi(x)} \right] \\
&= \mathbb{E}_{x\sim p_{\text{data}}} \left[\log p_{\text{data}}(x) - \log p_\phi(x) \right] \\
&= \mathbb{E}_{x\sim p_{\text{data}}} \left[\log p_{\text{data}}(x) \right] - \mathbb{E}_{x\sim p_{\text{data}}} \left[\log p_\phi(x) \right]
\end{aligned}$$



Divergencia KL

Entropía

La entropía de una distribución de probabilidad p_{data} es:

$$\mathcal{H}(p_{\text{data}}) := -\int p_{\text{data}}(x) \log p_{\text{data}}(x) dx = -\mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\text{data}}(x)]$$



Divergencia KL

Entropía

La entropía de una distribución de probabilidad p_{data} es:

$$\mathcal{H}(p_{\text{data}}) := -\int p_{\text{data}}(x) \log p_{\text{data}}(x) dx = -\mathbb{E}_{x \sim p_{\text{data}}} [\log p_{\text{data}}(x)]$$

Cálculo de la divergencia KL

$$\mathcal{D}_{\text{KL}}(p_{\text{data}} || p_\phi) = -\mathcal{H}(p_{\text{data}}) - \mathbb{E}_{x \sim p_{\text{data}}} [\log p_\phi(x)]$$



Minimización de la divergencia KL

¡$\mathcal{H}(p_{\text{data}})$ no depende de los parámetros ϕ!

Lema (Minimizar KL $\iff$ MLE)

$$\min_\phi \mathcal{D}_{KL}(p_{data}||p_\phi) \iff \max_\phi \mathbb{E}_{x\sim p_{data}}\left[\log p_\phi(x)\right]$$



Minimización de la divergencia KL

¡$\mathcal{H}(p_{\text{data}})$ no depende de los parámetros ϕ!

Lema (Minimizar KL $\iff$ MLE)

$$\min_\phi \mathcal{D}_{KL}(p_{data}||p_\phi) \iff \max_\phi \mathbb{E}_{x\sim p_{data}}[\log p_\phi(x)]$$

Estimando mediante Monte Carlo la esperanza (y teniendo en cuenta que se prefiere minimizar la función de pérdida), obtenemos la función de pérdida empleada en la práctica:

$$\hat{\mathcal{L}}_{\text{MLE}}(\phi) = -\frac{1}{N}\sum_{i=1}^{N}\log p_\phi(x_i) \qquad x_i \sim p_{\text{data}}$$



Divergencia de Fisher

Divergencia de Fisher

La divergencia de Fisher entre dos distribuciones de probabilidad p_{data} y p_ϕ es:

$$\mathcal{D}_{\text{F}}(p_{\text{data}}||p_\phi) := E_{x\sim p_{\text{data}}}\left[\|\nabla_x \log p_{\text{data}}(x) - \nabla_x \log p_\phi(x)\|_2^2\right]$$

donde se ha tomado la primera distribución p_{data} como referencia.

¿Por qué se emplean los logaritmos? ¿No se podría calcular sin ellos?



f-Divergencias

f-Divergencia

Sea $f : \mathbb{R}^+ \to \mathbb{R}$ una función convexa con $f(1) = 0$. La f-divergencia entre dos distribuciones de probabilidad p y q es:

$$\mathcal{D}_f(p||q) := \int q(x) f\left(\frac{p(x)}{q(x)}\right) dx$$



f-Divergencias

Casos particulares

- Divergencia KL directa $\mathcal{D}_{\mathrm{KL}}(p||q)$: $f(u) = u \log u$
- Divergencia de Jensen-Shannon $\mathcal{D}_{\mathrm{JS}}(p||q)$:

$$f(u) = \frac{1}{2}\left[u \log u - (u+1)\log\left(\frac{u+1}{2}\right)\right]$$

- Variación Total $\mathcal{D}_{\mathrm{TV}}(p||q)$: $f(u) = \frac{1}{2}|u-1|$



f-Divergencias

Casos particulares

- Divergencia KL directa $\mathcal{D}_{\mathrm{KL}}(p||q)$: $f(u) = u \log u$
- Divergencia de Jensen-Shannon $\mathcal{D}_{\mathrm{JS}}(p||q)$:

$$f(u) = \frac{1}{2}\left[u \log u - (u+1)\log\left(\frac{u+1}{2}\right)\right]$$

- Variación Total $\mathcal{D}_{\mathrm{TV}}(p||q)$: $f(u) = \frac{1}{2}|u-1|$

$$\mathcal{D}_{\mathrm{JS}}(p||q) = \frac{1}{2}\mathcal{D}_{\mathrm{KL}}\left(p||\frac{1}{2}(p+q)\right) + \frac{1}{2}\mathcal{D}_{\mathrm{KL}}\left(q||\frac{1}{2}(p+q)\right),$$

$$\mathcal{D}_{\mathrm{TV}}(p,q) = \frac{1}{2}\int |p-q|dx = \sup_{A\subset\mathbb{R}^D} |p(A) - q(A)|.$$



Índice

1 Objetivo de un DGM

2 Función de pérdida

3 Camino a obtener p_ϕ



Camino a obtener p_ϕ

Para que la función p_ϕ buscada sea realmente una función de densidad de probabilidad, debe cumplir:

1. No negatividad:

$$p_\phi(x) \geq 0 \qquad \forall x$$

2. Normalización:

$$\int p_\phi(x)dx = 1$$



Camino a obtener p_ϕ

Para que la función p_ϕ buscada sea realmente una función de densidad de probabilidad, debe cumplir:

1. No negatividad:
$$p_\phi(x) \geq 0 \qquad \forall x$$
2. Normalización:
$$\int p_\phi(x)dx = 1$$

La DNN puede producir $E_\phi(x) \in \mathbb{R}$ para cada entrada x, pero hemos de realizar varias transformaciones para obtener $p_\phi(x)$.



No negatividad

Para garantizar la no negatividad, podemos emplear cualquier función positiva a $E_\phi(x)$, como $|E_\phi(x)|$ o $(E_\phi(x))^2$.



No negatividad

Para garantizar la no negatividad, podemos emplear cualquier función positiva a $E_\phi(x)$, como $|E_\phi(x)|$ o $(E_\phi(x))^2$.

En la práctica, se emplea la función exponencial:

$$\tilde{p}_\phi(x) = \exp(E_\phi(x)) \geq 0 \qquad \forall x$$

