Capítulo 2.1. Variational Autoencoders

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

13 de julio de 2026



Índice

1. Autoencoders
2. Variational Autoencoders (VAEs)
3. Entrenamiento de VAEs
4. Gaussian VAEs



Autoencoders

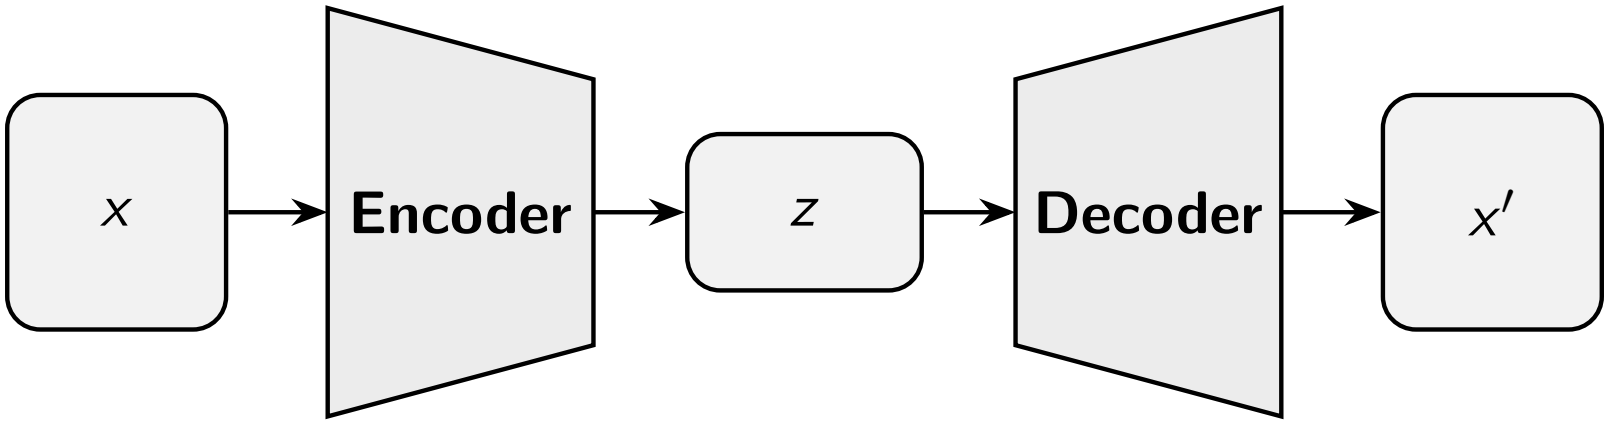


Figura 1: Esquema de un Autoencoder

El entrenamiento consiste en minimizar la función de pérdida $\mathcal{L}(x, x')$ que mide la diferencia entre la entrada x y la salida reconstruida x'.

Autoencoders

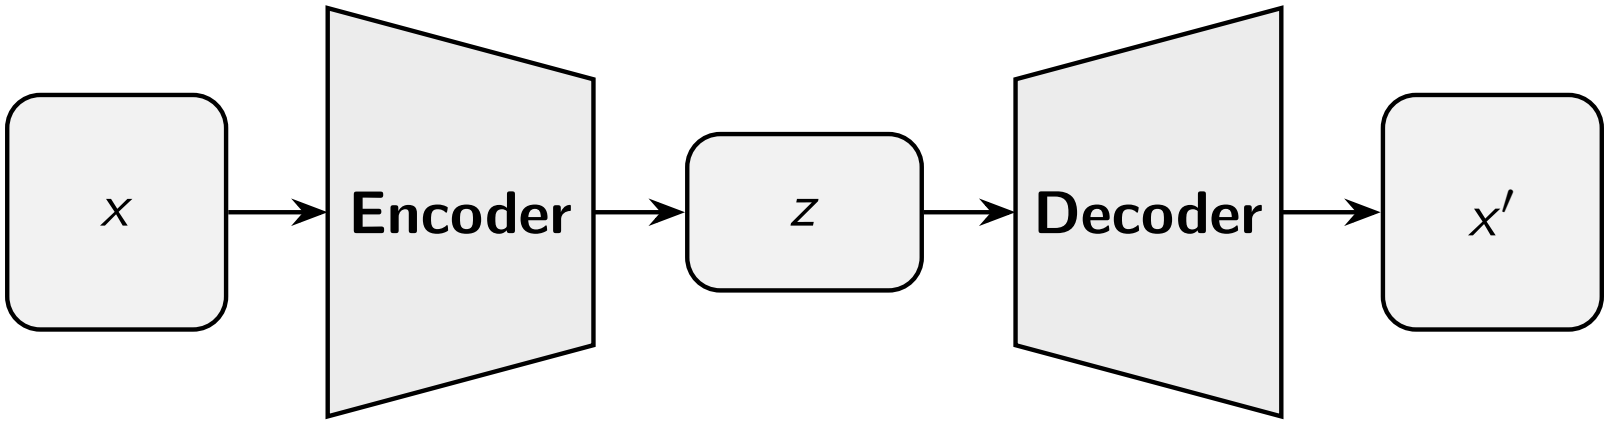


Figura 1: Esquema de un Autoencoder

El entrenamiento consiste en minimizar la función de pérdida $\mathcal{L}(x, x')$ que mide la diferencia entre la entrada x y la salida reconstruida x'.
Generar nuevas muestras con un autoencoder consiste en muestrear un vector latente $z \in \mathbb{R}^d$ y decodificarlo.

Problema de los Autoencoders



Problema de los Autoencoders

¡El espacio latente no está estructurado!
La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.



Problema de los Autoencoders

¡El espacio latente no está estructurado!
La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.

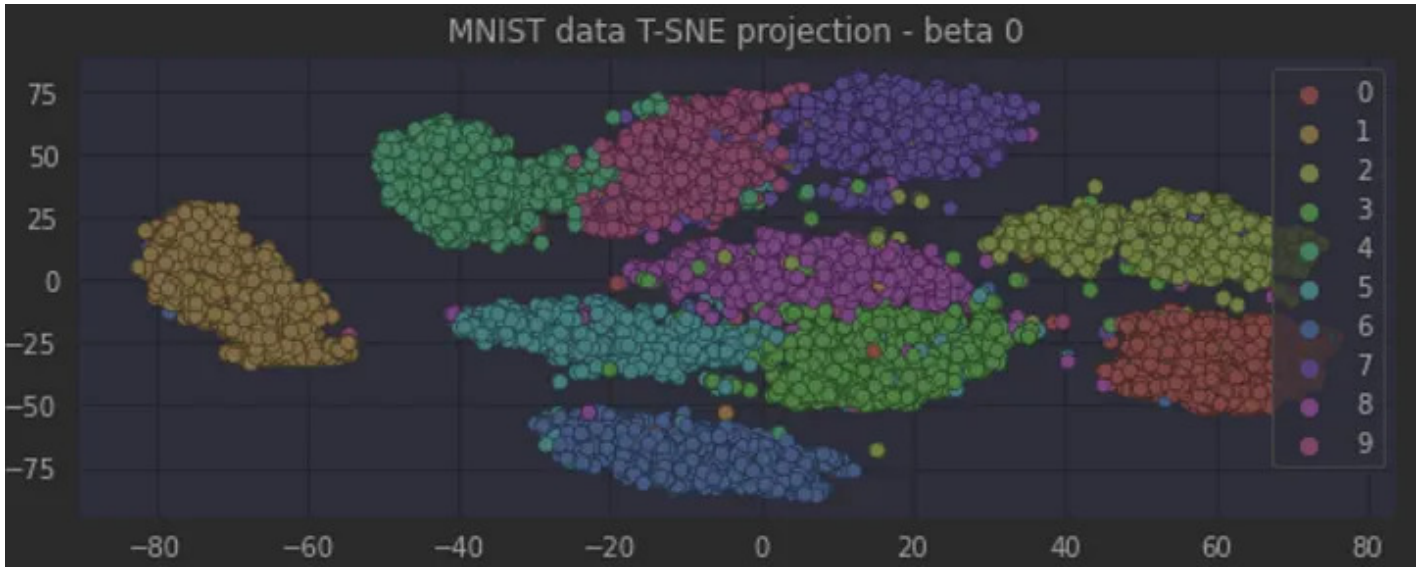


Figura 2: Espacio latente de un Autoencoder

Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs



Solución de los VAEs

Los VAEs resuelven el problema de los autoencoders de la siguiente manera:

- Se proporciona una estructura probabilística al espacio latente, forzando a que los vectores latentes sigan cierta distribución (normalmente, una distribución normal multivariante).

$$z \sim p_{\text{prior}}(z) = \mathcal{N}(0, I)$$



Solución de los VAEs

Los VAEs resuelven el problema de los autoencoders de la siguiente manera:

- Se proporciona una estructura probabilística al espacio latente, forzando a que los vectores latentes sigan cierta distribución (normalmente, una distribución normal multivariante).

$$z \sim p_{\text{prior}}(z) = \mathcal{N}(0, I)$$

- El encoder y el decoder no son funciones deterministas, sino que definen distribuciones de probabilidad condicionadas:

$$q_\theta(z \mid x) \quad \text{y} \quad p_\phi(x \mid z)$$



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.
2. Decodificar el vector latente z para obtener una distribución de probabilidad sobre los datos $p_\phi(x \mid z)$.



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.
2. Decodificar el vector latente z para obtener una distribución de probabilidad sobre los datos $p_\phi(x \mid z)$.
3. Muestrear un dato x de la distribución $p_\phi(x \mid z)$.



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z \mid x)$:

$$p_\phi(z \mid x) = \frac{p_\phi(x \mid z) p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x \mid z) p_{\text{prior}}(z)\, dz$$



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z \mid x)$:

$$p_\phi(z \mid x) = \frac{p_\phi(x \mid z) p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x \mid z) p_{\text{prior}}(z)\, dz$$

El cálculo de $p_\phi(x)$ es intractable, por lo que no se puede calcular $p_\phi(z \mid x)$ directamente.



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z \mid x)$:

$$p_\phi(z \mid x) = \frac{p_\phi(x \mid z) p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x \mid z) p_{\text{prior}}(z)\, dz$$

El cálculo de $p_\phi(x)$ es intractable, por lo que no se puede calcular $p_\phi(z \mid x)$ directamente.

El encoder se modela mediante una distribución de probabilidad $q_\theta(z \mid x)$ que aproxima a la distribución posterior $p_\phi(z \mid x)$:

$$q_\theta(z \mid x) \approx p_\phi(z \mid x)$$



Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs



Problema de la MLE

Como en todo DGM, el entrenamiento de un VAE consiste en maximizar la verosimilitud de los datos:

$$\max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}(x)}[\log p_\phi(x)]$$



Problema de la MLE

Como en todo DGM, el entrenamiento de un VAE consiste en maximizar la verosimilitud de los datos:

$$\max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}(x)}[\log p_\phi(x)]$$

Sin embargo, el cálculo de $p_\phi(x)$ es intractable, por lo que no se puede maximizar directamente la verosimilitud de los datos.



Componentes a entrenar en un VAE

Fijado un dato real x, un VAE tiene dos componentes a entrenar:

- Reconstrucción de datos: A partir de $z \sim q_\theta(z \mid x)$, la reconstrucción de x' mediante el decoder $p_\phi(x \mid z)$ debe ser lo más parecida posible a x.
  Se obtiene mediante la MLE de los datos reconstruidos:

$$\max_{\phi} \mathbb{E}_{z \sim q_\theta(z|x)}[\log p_\phi(x \mid z)]$$



Componentes a entrenar en un VAE

Fijado un dato real x, un VAE tiene dos componentes a entrenar:

- Reconstrucción de datos: A partir de $z \sim q_\theta(z \mid x)$, la reconstrucción de x' mediante el decoder $p_\phi(x \mid z)$ debe ser lo más parecida posible a x.
  Se obtiene mediante la MLE de los datos reconstruidos:

$$\max_{\phi} \mathbb{E}_{z \sim q_\theta(z|x)}[\log p_\phi(x \mid z)]$$

- Regularización del espacio latente: Para otorgarle estructura al espacio latente.

$$\min_{\theta} \mathcal{D}_{\mathrm{KL}}(q_\theta(z \mid x) \| p_{\mathrm{prior}}(z))$$



Evidence Lower Bound (ELBO)

Evidence Lower Bound (ELBO)

La **evidence lower bound** (ELBO) de un dato x es la siguiente función:

$$\mathcal{L}_{\text{ELBO}}(x;\theta,\phi) = \underbrace{\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x \mid z)]}_{\text{Reconstrucción de datos}} - \underbrace{\mathcal{D}_{\text{KL}}(q_\theta(z \mid x)\|p_{\text{prior}}(z))}_{\text{Regularización del espacio latente}}$$



Evidence Lower Bound (ELBO)

Evidence Lower Bound (ELBO)

La **evidence lower bound** (ELBO) de un dato x es la siguiente función:

$$\mathcal{L}_{\text{ELBO}}(x;\theta,\phi) = \underbrace{\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x \mid z)]}_{\text{Reconstrucción de datos}} - \underbrace{\mathcal{D}_{\text{KL}}(q_\theta(z \mid x)\|p_{\text{prior}}(z))}_{\text{Regularización del espacio latente}}$$

Aunque no se pueda maximizar directamente la verosimilitud de los datos, se puede maximizar la ELBO, que es un límite inferior de la verosimilitud:

Theorem (Evidence Lower Bound)

$$\log p_\phi(x) \geq \mathcal{L}_{ELBO}(x;\theta,\phi) \qquad \forall x$$



Cota Total del Error

En todo DGM, se busca minimizar $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))$. Puesto que no se puede calcular $p_\phi(x)$ y que los VAEs emplean un espacio latente, se define:

Cota Total del Error

Dado un VAE, la **cota total del error** es:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$

donde

$$q_\theta(x,z) = p_{\mathrm{data}}(x)q_\theta(z \mid x) \quad \text{y} \quad p_\phi(x,z) = p_{\mathrm{prior}}(z)p_\phi(x \mid z)$$



Cota Total del Error

En todo DGM, se busca minimizar $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))$. Puesto que no se puede calcular $p_\phi(x)$ y que los VAEs emplean un espacio latente, se define:

Cota Total del Error

Dado un VAE, la **cota total del error** es:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$

donde

$$q_\theta(x,z) = p_{\mathrm{data}}(x)q_\theta(z \mid x) \quad \text{y} \quad p_\phi(x,z) = p_{\mathrm{prior}}(z)p_\phi(x \mid z)$$

Aplicando la Regla de la Cadena de la Divergencia KL, se obtiene:

$$\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x)) \leq \mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$



Error de Inferencia

La cota total del error se puede descomponer en dos términos:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z)) =$$
$$= \underbrace{\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))}_{\text{Error Real de Modelado}} + \underbrace{\mathbb{E}_{x\sim p_{\mathrm{data}}(x)}[\mathcal{D}_{\mathrm{KL}}(q_\theta(z\mid x)\|p_\phi(z\mid x))]}_{\text{Error Medio de Inferencia}}$$



Error de Inferencia

La cota total del error se puede descomponer en dos términos:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z)) =$$
$$= \underbrace{\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))}_{\text{Error Real de Modelado}} + \underbrace{\mathbb{E}_{x\sim p_{\mathrm{data}}(x)}[\mathcal{D}_{\mathrm{KL}}(q_\theta(z\mid x)\|p_\phi(z\mid x))]}_{\text{Error Medio de Inferencia}}$$

El segundo término, el **error de inferencia**, mide la diferencia entre la distribución del espacio latente para un dato x, considerándolo tanto codificado como generado.



Error de Inferencia y ELBO

La siguiente relación entre el error de inferencia y la ELBO se cumple:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z \mid x) \| p_\phi(z \mid x)) = \log p_\phi(x) - \mathcal{L}_{\mathrm{ELBO}}(x; \theta, \phi)$$



Error de Inferencia y ELBO

La siguiente relación entre el error de inferencia y la ELBO se cumple:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z \mid x) \| p_\phi(z \mid x)) = \log p_\phi(x) - \mathcal{L}_{\mathrm{ELBO}}(x; \theta, \phi)$$

Por tanto, maximizar la ELBO es equivalente a minimizar el error de inferencia.



Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.Entonces:

Encoder: $q_\theta(z \mid x) := \mathcal{N}(z; \mu_\theta(x), \text{diag}(\sigma^2_\theta(x)))$

donde $\mu_\theta, \log \sigma^2_\theta : \mathbb{R}^D \to \mathbb{R}^d$ son las salidas de la red neuronal del encoder.



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.Entonces:

Encoder: $q_\theta(z \mid x) := \mathcal{N}(z; \mu_\theta(x), \text{diag}(\sigma^2_\theta(x)))$

donde $\mu_\theta, \log \sigma^2_\theta : \mathbb{R}^D \to \mathbb{R}^d$ son las salidas de la red neuronal del encoder.

Decoder: $p_\phi(x \mid z) := \mathcal{N}(x; \mu_\phi(z), \sigma^2 I)$

donde $\sigma^2 \in \mathbb{R}^+$ es un hiperparámetro y $\mu_\phi : \mathbb{R}^d \to \mathbb{R}^D$ es la salida de la red neuronal del decoder.



Entrenamiento de Gaussian VAEs

Las componentes de la ELBO para un Gaussian VAE se pueden calcular de manera analítica:

- Reconstrucción de datos:

$$\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x \mid z)] = -\frac{1}{2\sigma^2}\mathbb{E}_{z\sim q_\theta(z|x)}[\|x - \mu_\phi(z)\|^2] + C$$

donde C es una constante que no depende de los parámetros θ y ϕ.



Entrenamiento de Gaussian VAEs

Las componentes de la ELBO para un Gaussian VAE se pueden calcular de manera analítica:

- Reconstrucción de datos:

$$\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x \mid z)] = -\frac{1}{2\sigma^2}\mathbb{E}_{z\sim q_\theta(z|x)}[\|x - \mu_\phi(z)\|^2] + C$$

  donde C es una constante que no depende de los parámetros θ y ϕ.

- Regularización del espacio latente:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z \mid x)\|p_{\mathrm{prior}}(z))$$

  se puede calcular de manera analítica, ya que ambas distribuciones son normales multivariantes.



Entrenamiento de Gaussian VAEs

Por tanto, maximizar la ELBO de un Gaussian VAE es equivalente a:

$$\min_{\theta,\phi} \mathbb{E}_{x\sim q_\theta(z|x)} \left[\frac{1}{2\sigma^2} \|x - \mu_\phi(z)\|^2 \right] + \mathcal{D}_{\mathrm{KL}}(q_\theta(z \mid x) \| p_{\mathrm{prior}}(z))$$

