Capítulo 2.1. Variational Autoencoders

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

15 de julio de 2026



Índice

1. Autoencoders
2. Variational Autoencoders (VAEs)
3. Entrenamiento de VAEs
4. Gaussian VAEs
5. Hierarchical VAEs



Autoencoders

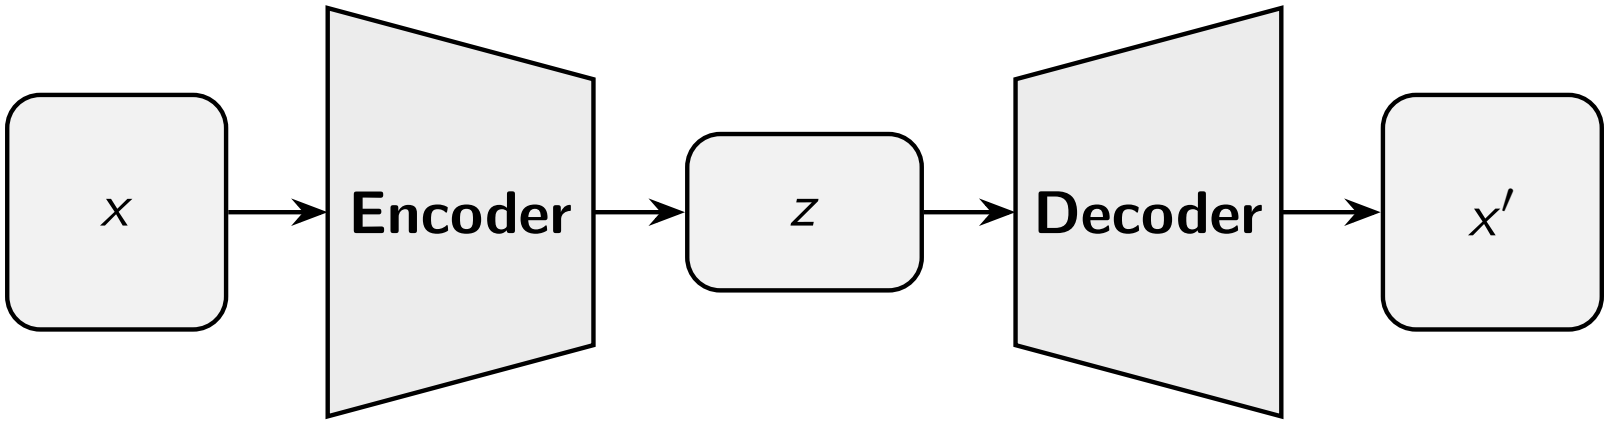


Figura 1: Esquema de un Autoencoder

Fuente: Autoría Propia, basado en [2].



Autoencoders

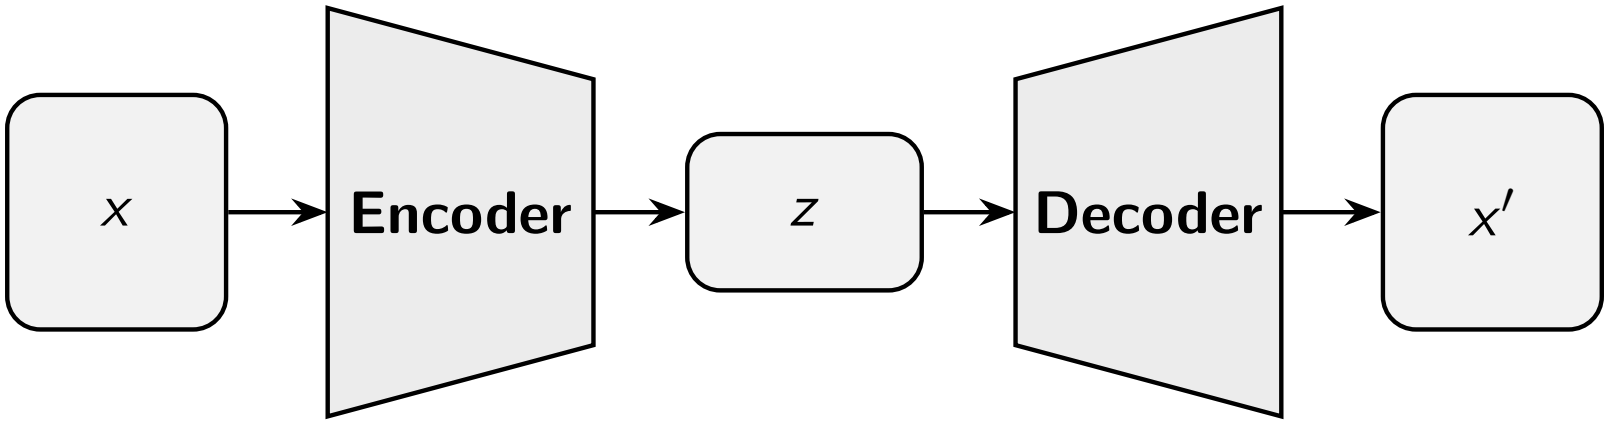


Figura 1: Esquema de un Autoencoder

Fuente: Autoría Propia, basado en [2].

Generar nuevas muestras con un autoencoder consiste en muestrear un vector latente $z \in \mathbb{R}^d$ y decodificarlo.

Problema de los Autoencoders

¡El espacio latente no está estructurado!

La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.



Problema de los Autoencoders

¡El espacio latente no está estructurado!
La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.

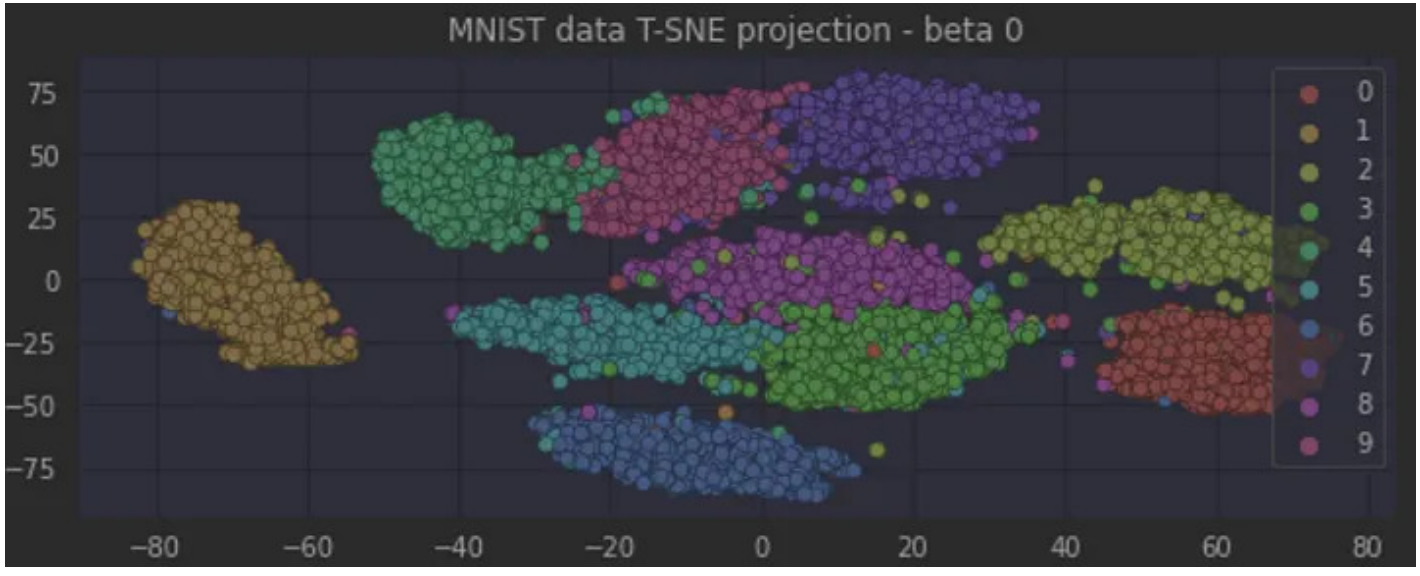


Figura 2: Espacio latente de un Autoencoder [1]

Problema de los Autoencoders

¡El espacio latente no está estructurado!
La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.

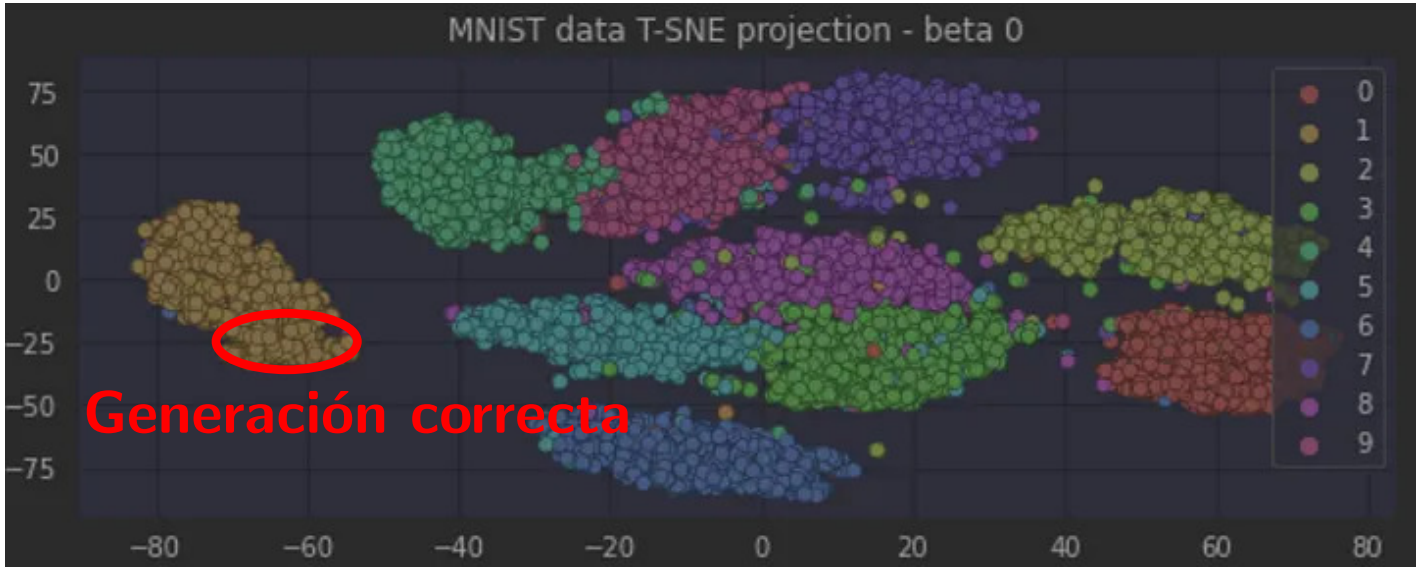


Figura 2: Espacio latente de un Autoencoder [1]

Problema de los Autoencoders

¡El espacio latente no está estructurado!
La mayoría de los vectores z generados aleatoriamente no corresponden a datos válidos.

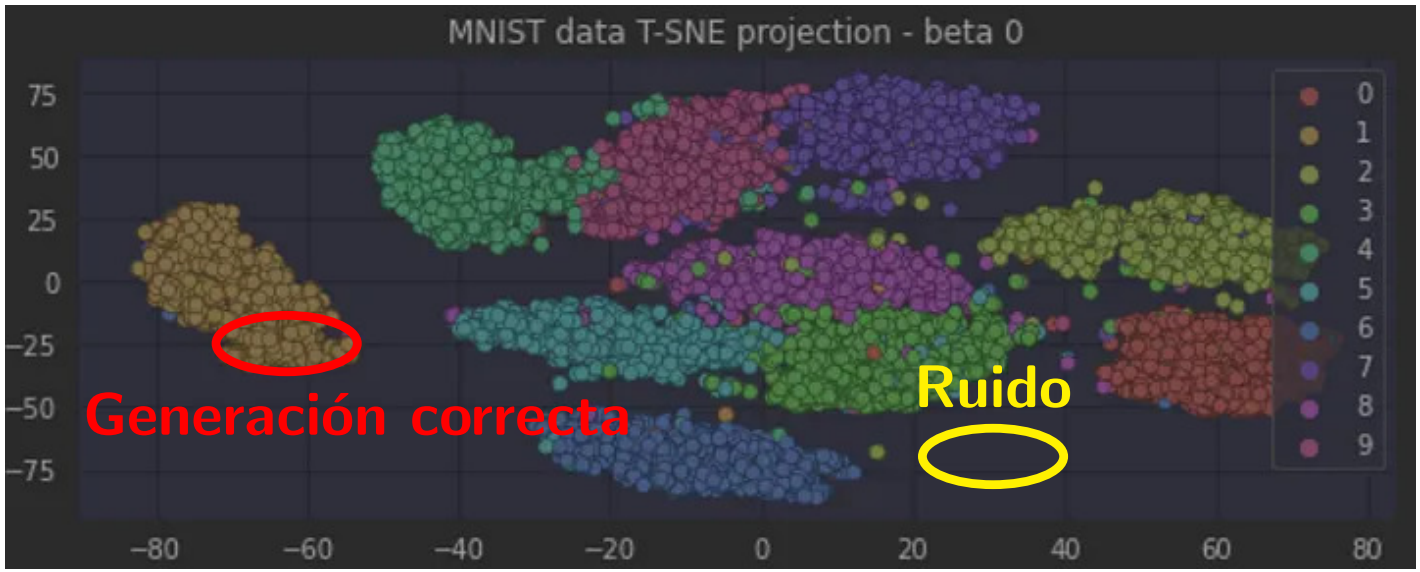


Figura 2: Espacio latente de un Autoencoder [1]

Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs

5 Hierarchical VAEs



Solución de los VAEs

Los VAEs resuelven el problema de los autoencoders de la siguiente manera:

- Se proporciona una estructura probabilística al espacio latente, forzando a que los vectores latentes sigan cierta distribución (normalmente, una distribución normal multivariante).

$$z \sim p_{\text{prior}}(z) = \mathcal{N}(0, I)$$



Solución de los VAEs

Los VAEs resuelven el problema de los autoencoders de la siguiente manera:

- Se proporciona una estructura probabilística al espacio latente, forzando a que los vectores latentes sigan cierta distribución (normalmente, una distribución normal multivariante).

$$z \sim p_{\text{prior}}(z) = \mathcal{N}(0, I)$$

- El encoder y el decoder no son funciones deterministas, sino que definen distribuciones de probabilidad condicionadas:

$$q_\theta(z|x) \quad \text{y} \quad p_\phi(x|z)$$



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.
2. Decodificar el vector latente z para obtener una distribución de probabilidad sobre los datos $p_\phi(x|z)$.



Generación de nuevas muestras con VAEs

Para generar nuevas muestras con un VAE, se sigue el siguiente procedimiento:

1. Muestrear un vector latente z de la distribución prior $p_{\text{prior}}(z)$.
2. Decodificar el vector latente z para obtener una distribución de probabilidad sobre los datos $p_\phi(x|z)$.
3. Muestrear un dato x de la distribución $p_\phi(x|z)$.



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z|x)$:

$$p_\phi(z|x) = \frac{p_\phi(x|z)p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x|z)p_{\text{prior}}(z)\ dz$$



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z|x)$:

$$p_\phi(z|x) = \frac{p_\phi(x|z)p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x|z)p_{\text{prior}}(z)\ dz$$

El cálculo de $p_\phi(x)$ es intractable, por lo que no se puede calcular $p_\phi(z|x)$ directamente.



Encoding de datos con VAEs

Para codificar un dato x con un VAE, aplicando la Regla de Bayes, se obtiene la distribución $p_\phi(z|x)$:

$$p_\phi(z|x) = \frac{p_\phi(x|z)p_{\text{prior}}(z)}{p_\phi(x)} \quad \text{donde } p_\phi(x) = \int p_\phi(x|z)p_{\text{prior}}(z)\, dz$$

El cálculo de $p_\phi(x)$ es intractable, por lo que no se puede calcular $p_\phi(z|x)$ directamente.

El encoder se modela mediante una distribución de probabilidad $q_\theta(z|x)$ que aproxima a la distribución posterior $p_\phi(z|x)$:

$$q_\theta(z|x) \approx p_\phi(z|x)$$



Interpolación en el espacio latente

Gracias a la estructura probabilística del espacio latente, no se pueden muestrear zonas del espacio latente vacías.



Interpolación en el espacio latente

Gracias a la estructura probabilística del espacio latente, no se pueden muestrear zonas del espacio latente vacías.
Como ejemplo de esto, se pueden interpolar vectores latentes para generar nuevas muestras, a diferencia de los autoencoders.

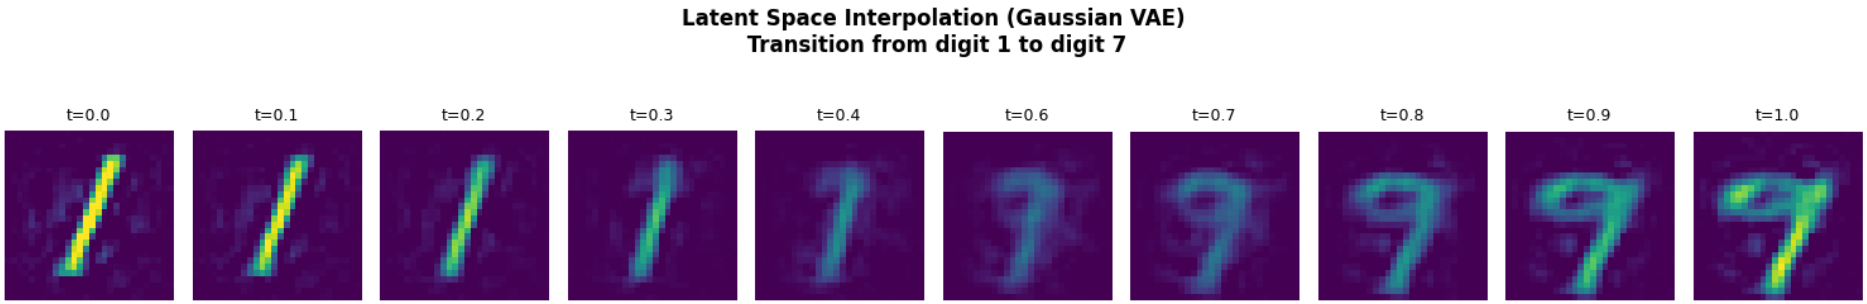


Figura 3: Interpolación en el espacio latente de un VAE

Fuente: Autoría propia, Repositorio VAE-MINST.

Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs

5 Hierarchical VAEs



Problema de la MLE

Como en todo DGM, el entrenamiento de un VAE consiste en maximizar la verosimilitud de los datos:

$$\max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}(x)}[\log p_\phi(x)]$$



Problema de la MLE

Como en todo DGM, el entrenamiento de un VAE consiste en maximizar la verosimilitud de los datos:

$$\max_{\phi} \mathbb{E}_{x \sim p_{\text{data}}(x)}[\log p_\phi(x)]$$

Sin embargo, el cálculo de $p_\phi(x)$ es intractable, por lo que no se puede maximizar directamente la verosimilitud de los datos.



Componentes a entrenar en un VAE

Fijado un dato real x, un VAE tiene dos componentes a entrenar:

- Reconstrucción de datos: A partir de $z \sim q_\theta(z|x)$, la reconstrucción de x' mediante el decoder $p_\phi(x|z)$ debe ser lo más parecida posible a x.
  Se obtiene mediante la MLE de los datos reconstruidos:

$$\max_\phi \mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)]$$



Componentes a entrenar en un VAE

Fijado un dato real x, un VAE tiene dos componentes a entrenar:

- Reconstrucción de datos: A partir de $z \sim q_\theta(z|x)$, la reconstrucción de x' mediante el decoder $p_\phi(x|z)$ debe ser lo más parecida posible a x.
  Se obtiene mediante la MLE de los datos reconstruidos:

$$\max_\phi \mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)]$$

- Regularización del espacio latente: Para otorgarle estructura al espacio latente.

$$\min_\theta \mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_{\mathrm{prior}}(z))$$



Evidence Lower Bound (ELBO)

Evidence Lower Bound (ELBO)

La **evidence lower bound** (ELBO) de un dato x es la siguiente función:

$$\mathcal{L}_{\text{ELBO}}(x;\theta,\phi) = \underbrace{\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)]}_{\text{Reconstrucción de datos}} - \underbrace{\mathcal{D}_{\text{KL}}(q_\theta(z|x)\|p_{\text{prior}}(z))}_{\text{Regularización del espacio latente}}$$



Evidence Lower Bound (ELBO)

Evidence Lower Bound (ELBO)

La **evidence lower bound** (ELBO) de un dato x es la siguiente función:

$$\mathcal{L}_{\text{ELBO}}(x;\theta,\phi) = \underbrace{\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)]}_{\text{Reconstrucción de datos}} - \underbrace{\mathcal{D}_{\text{KL}}(q_\theta(z|x)\|p_{\text{prior}}(z))}_{\text{Regularización del espacio latente}}$$

Aunque no se pueda maximizar directamente la verosimilitud de los datos, se puede maximizar la ELBO, que es un límite inferior de la verosimilitud:

Theorem (Evidence Lower Bound)

$$\log p_\phi(x) \geq \mathcal{L}_{ELBO}(x;\theta,\phi) \qquad \forall x$$



Cota Total del Error

En todo DGM, se busca minimizar $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))$. Puesto que no se puede calcular $p_\phi(x)$ y que los VAEs emplean un espacio latente, se define:

Cota Total del Error

Dado un VAE, la **cota total del error** es:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$

donde

$$q_\theta(x,z) = p_{\mathrm{data}}(x)q_\theta(z|x) \quad \text{y} \quad p_\phi(x,z) = p_{\mathrm{prior}}(z)p_\phi(x|z)$$



Cota Total del Error

En todo DGM, se busca minimizar $\mathcal{D}_{\mathrm{KL}}(p_{\text{data}}(x)\|p_\phi(x))$. Puesto que no se puede calcular $p_\phi(x)$ y que los VAEs emplean un espacio latente, se define:

Cota Total del Error

Dado un VAE, la **cota total del error** es:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$

donde

$$q_\theta(x,z) = p_{\text{data}}(x)q_\theta(z|x) \quad \text{y} \quad p_\phi(x,z) = p_{\text{prior}}(z)p_\phi(x|z)$$

Aplicando la Regla de la Cadena de la Divergencia KL, se obtiene:

$$\mathcal{D}_{\mathrm{KL}}(p_{\text{data}}(x)\|p_\phi(x)) \leq \mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z))$$



Error de Inferencia

La cota total del error se puede descomponer en dos términos:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z)) =$$
$$= \underbrace{\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))}_{\text{Error Real de Modelado}} + \underbrace{\mathbb{E}_{x\sim p_{\mathrm{data}}(x)}[\mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_\phi(z|x))]}_{\text{Error Medio de Inferencia}}$$



Error de Inferencia

La cota total del error se puede descomponer en dos términos:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(x,z)\|p_\phi(x,z)) =$$
$$= \underbrace{\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}}(x)\|p_\phi(x))}_{\text{Error Real de Modelado}} + \underbrace{\mathbb{E}_{x\sim p_{\mathrm{data}}(x)}[\mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_\phi(z|x))]}_{\text{Error Medio de Inferencia}}$$

El segundo término, el **error de inferencia**, mide la diferencia entre la distribución del espacio latente para un dato x, considerándolo tanto codificado como generado.



Error de Inferencia y ELBO

La siguiente relación entre el error de inferencia y la ELBO se cumple:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_\phi(z|x)) = \log p_\phi(x) - \mathcal{L}_{\mathrm{ELBO}}(x;\theta,\phi)$$



Error de Inferencia y ELBO

La siguiente relación entre el error de inferencia y la ELBO se cumple:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_\phi(z|x)) = \log p_\phi(x) - \mathcal{L}_{\mathrm{ELBO}}(x;\theta,\phi)$$

Por tanto, maximizar la ELBO es equivalente a minimizar el error de inferencia.



Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs

5 Hierarchical VAEs



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.Entonces:

Encoder: $q_\theta(z|x) := \mathcal{N}(z; \mu_\theta(x), \text{diag}(\sigma^2_\theta(x)))$

donde $\mu_\theta, \log \sigma^2_\theta : \mathbb{R}^D \to \mathbb{R}^d$ son las salidas de la red neuronal del encoder.



Gaussian VAEs

En los Gaussian VAEs, el encoder y el decoder se modelan mediante distribuciones normales multivariantes. Sean $D, d \in \mathbb{N}$ las dimensiones de los datos y del espacio latente, respectivamente.Entonces:

Encoder: $q_\theta(z|x) := \mathcal{N}(z; \mu_\theta(x), \text{diag}(\sigma^2_\theta(x)))$

donde $\mu_\theta, \log \sigma^2_\theta : \mathbb{R}^D \to \mathbb{R}^d$ son las salidas de la red neuronal del encoder.

Decoder: $p_\phi(x|z) := \mathcal{N}(x; \mu_\phi(z), \sigma^2 I)$

donde $\sigma^2 \in \mathbb{R}^+$ es un hiperparámetro y $\mu_\phi : \mathbb{R}^d \to \mathbb{R}^D$ es la salida de la red neuronal del decoder.



Entrenamiento de Gaussian VAEs

Las componentes de la ELBO para un Gaussian VAE se pueden calcular de manera analítica:

- Reconstrucción de datos:

$$\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)] = -\frac{1}{2\sigma^2}\mathbb{E}_{z\sim q_\theta(z|x)}[\|x-\mu_\phi(z)\|^2] + C$$

donde C es una constante que no depende de los parámetros θ y ϕ.



Entrenamiento de Gaussian VAEs

Las componentes de la ELBO para un Gaussian VAE se pueden calcular de manera analítica:

- Reconstrucción de datos:

$$\mathbb{E}_{z\sim q_\theta(z|x)}[\log p_\phi(x|z)] = -\frac{1}{2\sigma^2}\mathbb{E}_{z\sim q_\theta(z|x)}[\|x-\mu_\phi(z)\|^2] + C$$

  donde C es una constante que no depende de los parámetros θ y ϕ.

- Regularización del espacio latente:

$$\mathcal{D}_{\mathrm{KL}}(q_\theta(z|x)\|p_{\mathrm{prior}}(z))$$

  se puede calcular de manera analítica, ya que ambas distribuciones son normales multivariantes.



Entrenamiento de Gaussian VAEs

Por tanto, maximizar la ELBO de un Gaussian VAE es equivalente a:

$$\min_{\theta,\phi} \mathbb{E}_{x\sim q_\theta(z|x)} \left[\frac{1}{2\sigma^2} \|x - \mu_\phi(z)\|^2 \right] + \mathcal{D}_{\mathrm{KL}}(q_\theta(z|x) \| p_{\mathrm{prior}}(z))$$



Problema de los Gaussian VAEs

Supuesto un encoder $q_{\text{enc}}(z|x)$ gaussiano y fijo[1], la función de pérdida de un Gaussian VAE quedaría:

$$\min_{\phi} \mathbb{E}_{x \sim p_{\text{data}}(x) q_{\text{enc}}(z|x)} \left[\|x - \mu_{\phi}(z)\|^2 \right]$$

[1] Esto no ocurre en la práctica, puesto que el encoder y el decoder se entrenan simultáneamente.



Problema de los Gaussian VAEs

Supuesto un encoder $q_{\text{enc}}(z|x)$ gaussiano y fijo[1], la función de pérdida de un Gaussian VAE quedaría:

$$\min_{\phi} \mathbb{E}_{x\sim p_{\text{data}}(x) q_{\text{enc}}(z|x)} \left[\|x - \mu_\phi(z)\|^2\right]$$

Esto es un problema de mínimos cuadrados en $\mu_\phi(z)$, con solución óptima:

$$\mu^*_\phi(z) = \mathbb{E}_{z\sim q_{\text{enc}}(x|z)}[x] = \frac{\mathbb{E}_{x\sim p_{\text{data}}(x)}[q_{\text{enc}}(z|x)\cdot x]}{\mathbb{E}_{x\sim p_{\text{data}}(x)}[q_{\text{enc}}(z|x)]}$$

[1] Esto no ocurre en la práctica, puesto que el encoder y el decoder se entrenan simultáneamente.

Problema de los Gaussian VAEs

Supuesto un encoder $q_{\text{enc}}(z|x)$ gaussiano y fijo[1], la función de pérdida de un Gaussian VAE quedaría:

$$\min_{\phi} \mathbb{E}_{x\sim p_{\text{data}}(x) q_{\text{enc}}(z|x)} \left[\|x - \mu_\phi(z)\|^2\right]$$

Esto es un problema de mínimos cuadrados en $\mu_\phi(z)$, con solución óptima:

$$\mu^*_\phi(z) = \mathbb{E}_{z\sim q_{\text{enc}}(x|z)}[x] = \frac{\mathbb{E}_{x\sim p_{\text{data}}(x)}[q_{\text{enc}}(z|x)\cdot x]}{\mathbb{E}_{x\sim p_{\text{data}}(x)}[q_{\text{enc}}(z|x)]}$$

La solución óptima $\mu^*_\phi(z)$ es una media ponderada de todos los datos x (posiblemente no relacionados entre sí) que codifican al mismo vector latente z, lo que provoca que la salida del decoder sea borrosa.

[1] Esto no ocurre en la práctica, puesto que el encoder y el decoder se entrenan simultáneamente.

Otras variantes de VAEs

Los Gaussian VAEs no son la única variante de VAEs. Existen otras variantes que buscan mejorar la calidad de las muestras generadas.

- **Gaussian Encoder and Bernoulli Decoder:**
  Permite modelar datos binarios, como imágenes en blanco y negro. Es muy común en la generación de números empleando el MNIST dataset.



Otras variantes de VAEs

Los Gaussian VAEs no son la única variante de VAEs. Existen otras variantes que buscan mejorar la calidad de las muestras generadas.

- **Gaussian Encoder and Bernoulli Decoder:**
  Permite modelar datos binarios, como imágenes en blanco y negro. Es muy común en la generación de números empleando el MNIST dataset.

Implementación de un Gaussian VAE y Bernoulli VAE

En este enlace, se pueden ver la implementación y los resultados de un Gaussian VAE y de un Bernouilli VAE empleando el MNIST dataset.



Problemas de los VAEs

1. El modelo elegido supone una gran limitación.
   Por ejemplo, si $p_\phi(z|x)$ es multimodal y hemos optado por un Gaussian Encoder, no podremos aproximarla bien, y no llegaremos a buenos resultados.



Problemas de los VAEs

1. El modelo elegido supone una gran limitación.
   Por ejemplo, si $p_\phi(z|x)$ es multimodal y hemos optado por un Gaussian Encoder, no podremos aproximarla bien, y no llegaremos a buenos resultados.
2. Si el Decoder es muy expresivo, puede terminar decodificando bien sin necesidad de usar la variable latente z.
   Esto provoca que $q_\theta(z) = p_{\text{prior}}(z)$, y que perdamos el control sobre la generación de nuevas muestras.



Índice

1 Autoencoders

2 Variational Autoencoders (VAEs)

3 Entrenamiento de VAEs

4 Gaussian VAEs

5 Hierarchical VAEs



Hierarchical VAEs

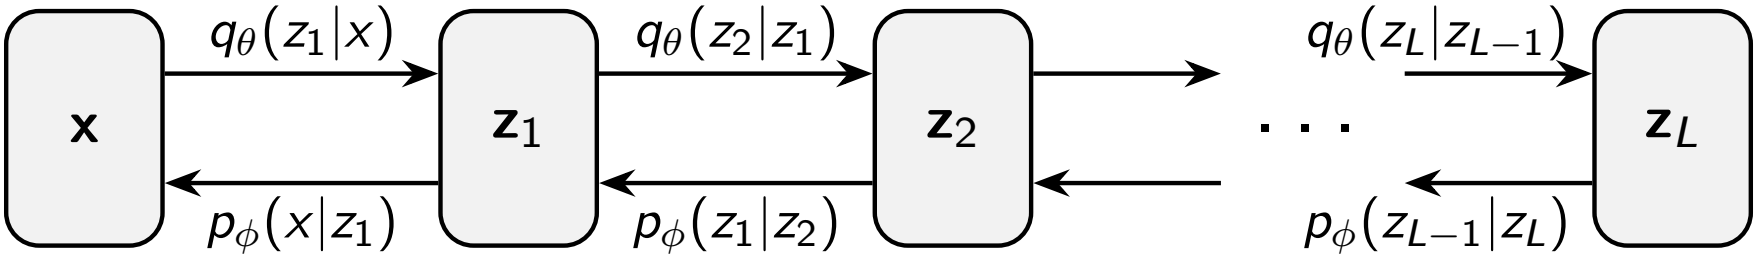


Figura 4: Esquema de un Hierarchical VAE

Fuente: Autoría Propia, basado en [2].

Se emplean varias capas latentes $z_1, z_2, \ldots, z_L$ para modelar la distribución de los datos.

Hierarchical VAEs

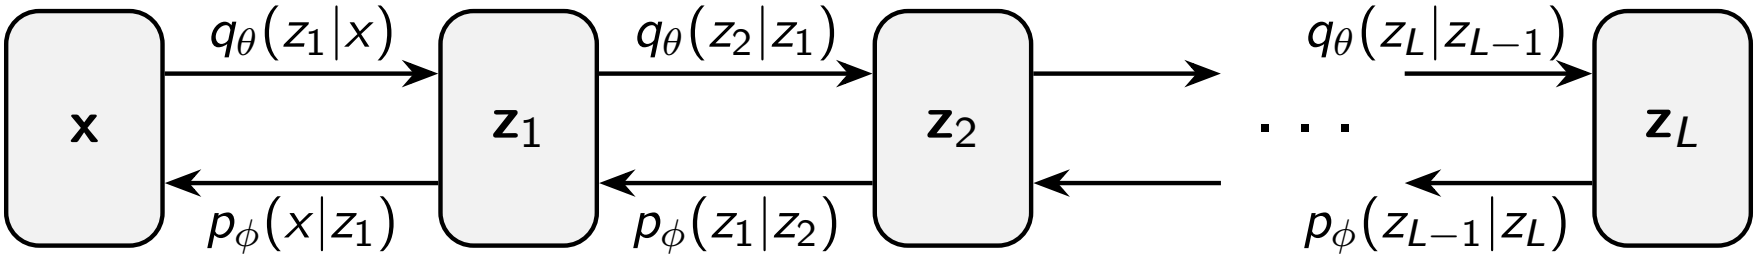


Figura 4: Esquema de un Hierarchical VAE

Fuente: Autoría Propia, basado en [2].

Se emplean varias capas latentes $z_1, z_2, \ldots, z_L$ para modelar la distribución de los datos.Tienen dos principales problemas:

1. El entrenamiento se vuelve inestable, ya que el error se propaga a través de todas las capas latentes.

Hierarchical VAEs

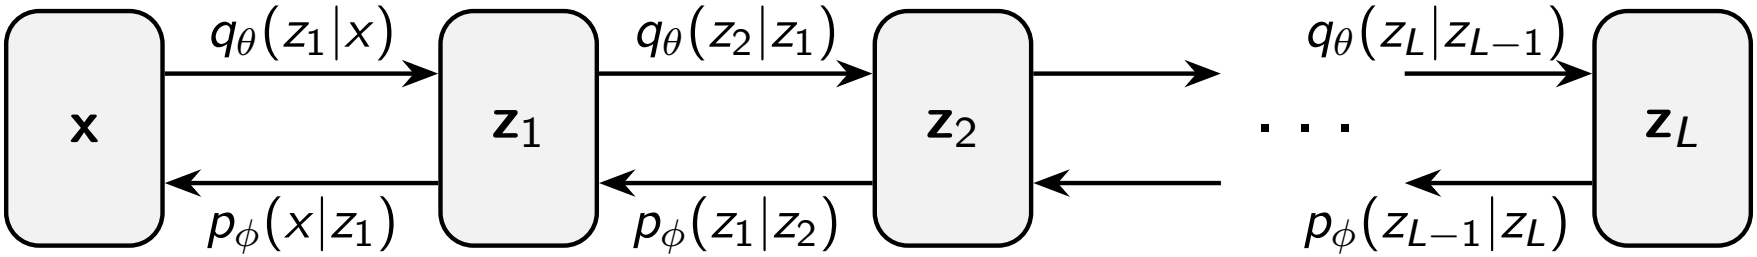


Figura 4: Esquema de un Hierarchical VAE

Fuente: Autoría Propia, basado en [2].

Se emplean varias capas latentes $z_1, z_2, \ldots, z_L$ para modelar la distribución de los datos.Tienen dos principales problemas:

1. El entrenamiento se vuelve inestable, ya que el error se propaga a través de todas las capas latentes.
2. Las capas más profundas tienden a ser ignoradas, ya que las capas más superficiales pueden modelar la distribución de los datos por solas.

Bibliografía I

[1] Ludovico Buizza. *Applying VAEs to MNIST*. Medium. 27 de mayo de 2020. URL: https://ludovico-buizza.medium.com/generating-things-with-vaes-882c6e3b688d (visitado 15-07-2026).

[2] Chieh-Hsin Lai et al. *The Principles of Diffusion Models*. 2026. arXiv: 2510.21890 [cs.LG]. URL: https://arxiv.org/abs/2510.21890.

