Capítulo 2.2. Denoising Diffusion Probabilistic Models

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

12 de octubre de 2026



Índice

1 Introducción

2 Forward Process

3 Reverse Process

4 ELBO de DDPM

5 Sampling



Denoising Diffusion Probabilistic Models

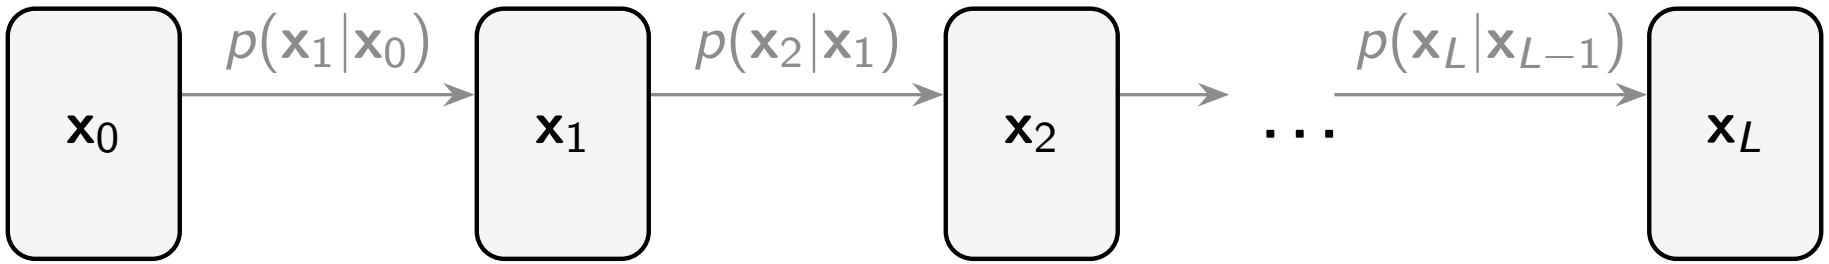


Figura 1: Cadena de difusión directa e inversa

Fuente: Autoría Propia, basado en [1].

Dos etapas, cada una de L pasos:

- Forward Process: En cada paso, se añade ruido al dato original. Es fijado y no se aprende.

Denoising Diffusion Probabilistic Models

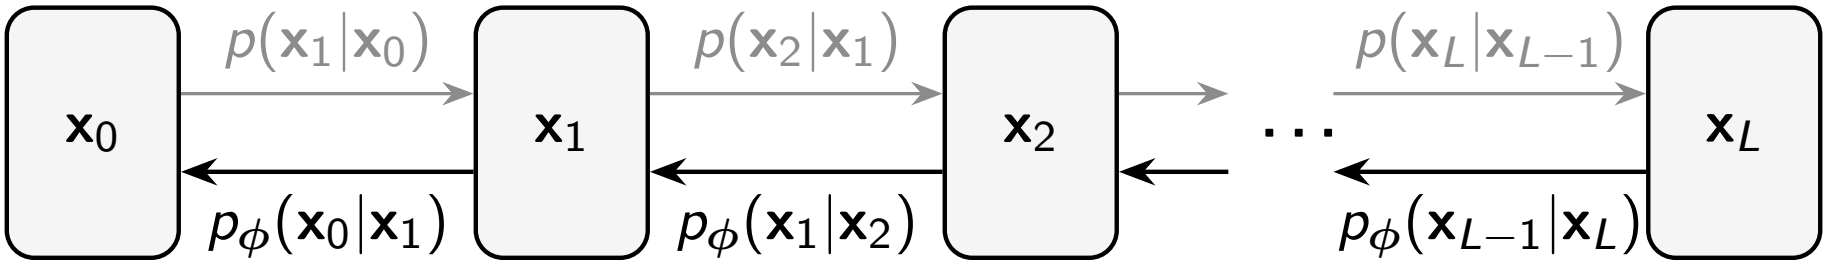


Figura 1: Cadena de difusión directa e inversa

Fuente: Autoría Propia, basado en [1].

Dos etapas, cada una de L pasos:

- Forward Process: En cada paso, se añade ruido al dato original. Es fijado y no se aprende.
- Reverse Process: En cada paso, se elimina el ruido del dato ruidoso. Se aprende a través de una red neuronal.

Índice

1 Introducción

2 Forward Process

3 Reverse Process

4 ELBO de DDPM

5 Sampling



Forward Process

Proceso *fijo* (no aprendido) que transforma un dato original $\mathbf{x}_0$ en ruido puro $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ a través de L pasos de difusión.



Forward Process

Proceso *fijo* (no aprendido) que transforma un dato original $\mathbf{x}_0$ en ruido puro $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ a través de L pasos de difusión. En cada paso, se añade ruido gaussiano al dato ruidoso del paso anterior:

$$x_i = \alpha_i x_{i-1} + \beta_i \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad i = 1, \ldots, L$$



Forward Process

Proceso *fijo* (no aprendido) que transforma un dato original $\mathbf{x}_0$ en ruido puro $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ a través de L pasos de difusión. En cada paso, se añade ruido gaussiano al dato ruidoso del paso anterior:

$$x_i = \alpha_i x_{i-1} + \beta_i \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad i = 1, \ldots, L$$

- La varianza se fuerza a $\mathbf{I}$ en cada paso, luego:

$$Var[x_i] = \alpha_i^2 Var[x_{i-1}] + \beta_i^2 \mathbf{I} = \mathbf{I} \implies \alpha_i^2 + \beta_i^2 = 1 \implies \alpha_i = \sqrt{1 - \beta_i^2}$$



Forward Process

Proceso *fijo* (no aprendido) que transforma un dato original $\mathbf{x}_0$ en ruido puro $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ a través de L pasos de difusión. En cada paso, se añade ruido gaussiano al dato ruidoso del paso anterior:

$$x_i = \alpha_i x_{i-1} + \beta_i \epsilon_i, \quad \epsilon_i \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad i = 1, \ldots, L$$

- La varianza se fuerza a $\mathbf{I}$ en cada paso, luego:

$$Var[x_i] = \alpha_i^2 Var[x_{i-1}] + \beta_i^2 \mathbf{I} = \mathbf{I} \implies \alpha_i^2 + \beta_i^2 = 1 \implies \alpha_i = \sqrt{1 - \beta_i^2}$$

- La distribución de x_i dado x_{i-1} es:

$$p_i(x_i | x_{i-1}) = \mathcal{N}(x_i; \alpha_i x_{i-1}, \beta_i^2 \mathbf{I})$$



Noise Schedule

El valor de x_i puede expresarse en función de x_0 y un único término de ruido ϵ:

$$x_i = \bar{\alpha}_i x_0 + \bar{\beta}_i \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad i = 1, \ldots, L$$

donde:

$$\bar{\alpha}_i = \prod_{k=1}^{i} \alpha_k, \quad \bar{\beta}_i = \sqrt{1 - \bar{\alpha}_i^2}$$



Noise Schedule

El valor de x_i puede expresarse en función de x_0 y un único término de ruido ϵ:

$$x_i = \bar{\alpha}_i x_0 + \bar{\beta}_i \epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad i = 1, \ldots, L$$

donde:

$$\bar{\alpha}_i = \prod_{k=1}^{i} \alpha_k, \quad \bar{\beta}_i = \sqrt{1 - \bar{\alpha}_i^2}$$

Como se va buscando que $x_L \sim p_L(x_L|x_0)$ se aproxime a $\mathcal{N}(\mathbf{0}, \mathbf{I})$, se fuerza que $\{\bar{\alpha}_i\}_{i=1}^{L} \searrow 0$. Esto se buscando una secuencia de $\{\beta_i\}_{i=1}^{L}$ creciente, donde $\beta_i \in]0, 1[$. Esto se conoce como **schedule** de ruido.



Ejemplo de Noise Schedule

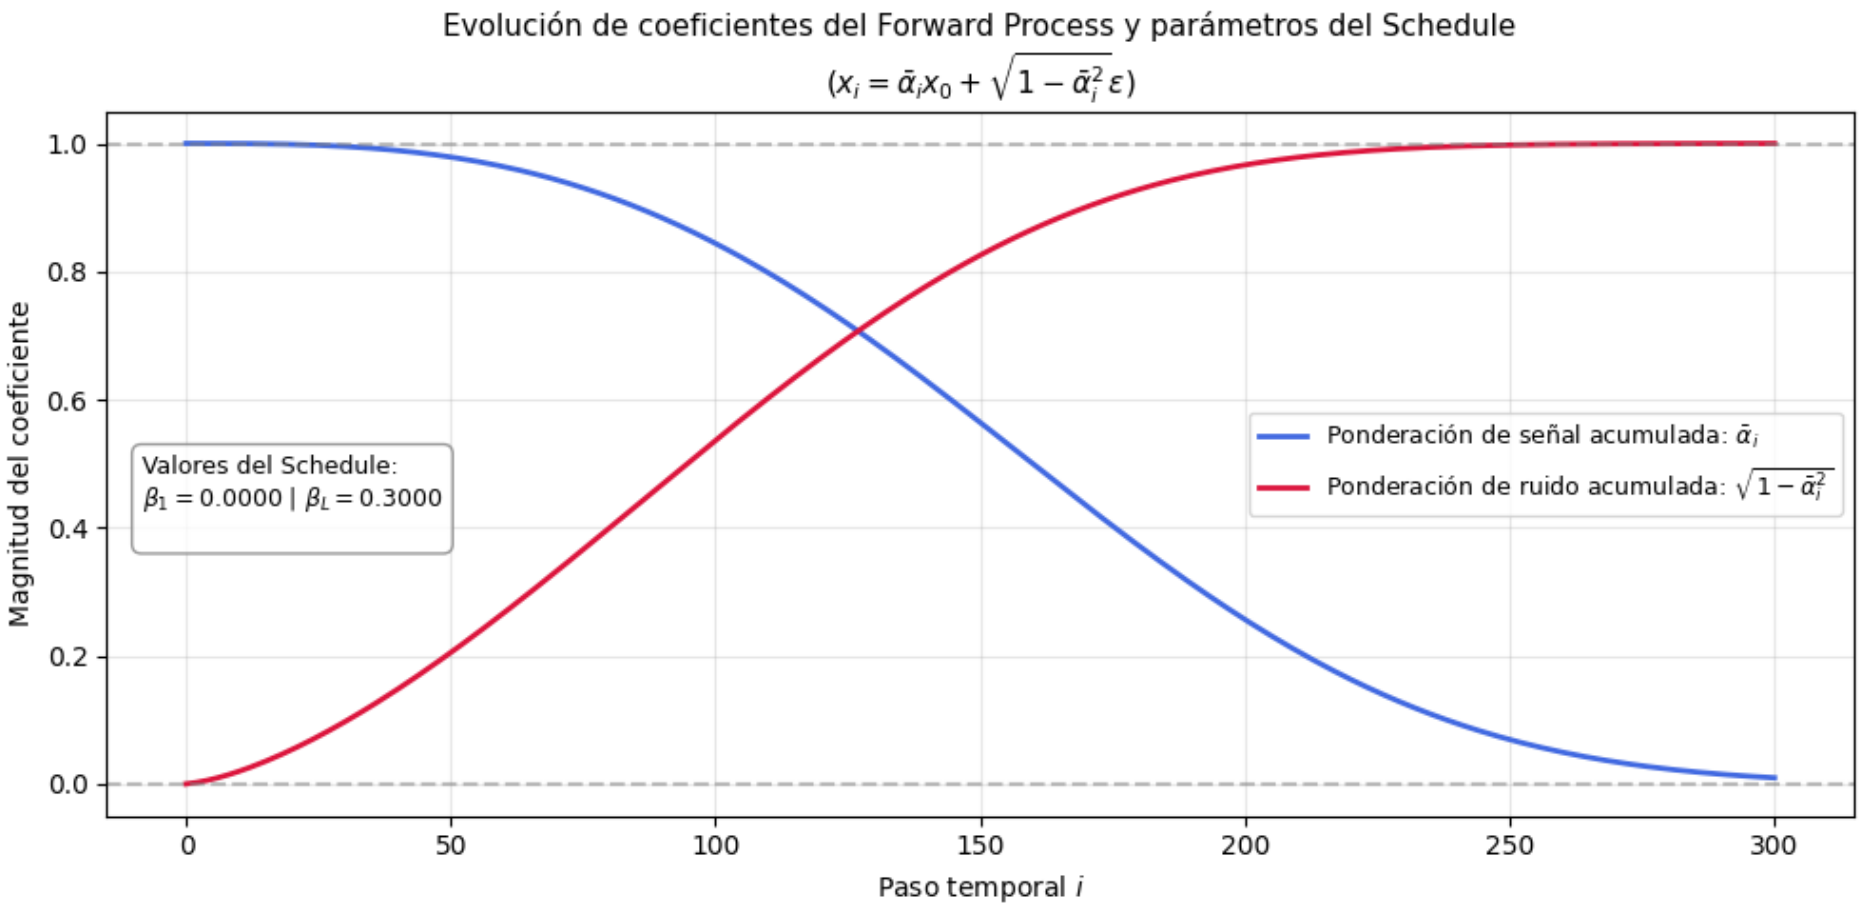


Figura 2: Ejemplo de schedule de ruido.

Fuente: Autoría propia [2].

Ejemplo de Forward Process

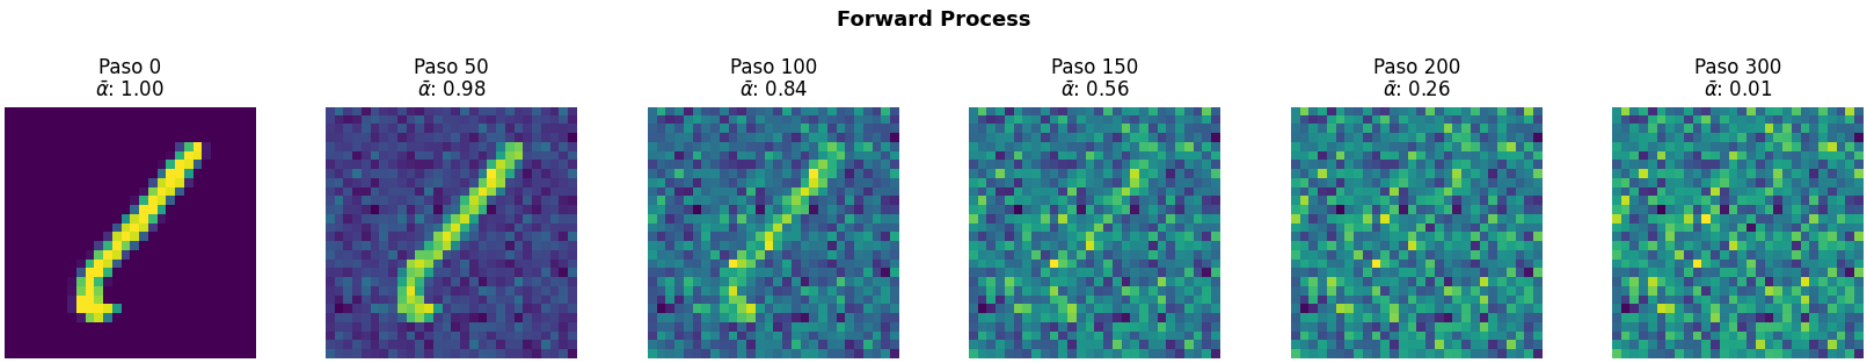


Figura 3: Ejemplo de Forward Process.

Fuente: Autoría propia [2].

Índice

1 Introducción

2 Forward Process

3 Reverse Process

4 ELBO de DDPM

5 Sampling



Reverse Process

Proceso *aprendido* que transforma un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ en un dato original $\mathbf{x}_0$ a través de L pasos de difusión inversa.



Reverse Process

Proceso *aprendido* que transforma un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ en un dato original $\mathbf{x}_0$ a través de L pasos de difusión inversa. Por la Regla de Bayes, la distribución de x_{i-1} dado x_i es:

$$p_i(x_{i-1}|x_i) = \frac{p_i(x_i|x_{i-1})p_{i-1}(x_{i-1})}{p_i(x_i)} \qquad p_i(x_i) = \int p_i(x_i|x_0)p_{\text{data}}(x_0)\, dx_0$$



Reverse Process

Proceso *aprendido* que transforma un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ en un dato original $\mathbf{x}_0$ a través de L pasos de difusión inversa. Por la Regla de Bayes, la distribución de x_{i-1} dado x_i es:

$$p_i(x_{i-1}|x_i) = \frac{p_i(x_i|x_{i-1})p_{i-1}(x_{i-1})}{p_i(x_i)} \qquad p_i(x_i) = \int p_i(x_i|x_0)p_{\text{data}}(x_0)\, dx_0$$

¡Intractable!



Reverse Process

Proceso *aprendido* que transforma un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ en un dato original $\mathbf{x}_0$ a través de L pasos de difusión inversa. Por la Regla de Bayes, la distribución de x_{i-1} dado x_i es:

$$p_i(x_{i-1}|x_i) = \frac{p_i(x_i|x_{i-1})p_{i-1}(x_{i-1})}{p_i(x_i)} \qquad p_i(x_i) = \int p_i(x_i|x_0)p_{\text{data}}(x_0)\, dx_0$$

¡Intractable!

Se aproxima $p_i(x_{i-1}|x_i)$ empleando una red neuronal $p_\phi(x_{i-1}|x_i)$, que se entrena para minimizar la divergencia KL entre ambas distribuciones.

$$\phi^* = \arg\min_\phi \mathbb{E}_{x_i \sim p_i(x_i)} \left[\mathcal{D}_{\text{KL}}\left(p_i(x_{i-1}|x_i)||p_\phi(x_{i-1}|x_i)\right)\right]$$



Reverse Process

Proceso *aprendido* que transforma un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ en un dato original $\mathbf{x}_0$ a través de L pasos de difusión inversa. Por la Regla de Bayes, la distribución de x_{i-1} dado x_i es:

$$p_i(x_{i-1}|x_i) = \frac{p_i(x_i|x_{i-1})p_{i-1}(x_{i-1})}{p_i(x_i)} \qquad p_i(x_i) = \int p_i(x_i|x_0)p_{\text{data}}(x_0)\, dx_0$$

¡Intractable!

Se aproxima $p_i(x_{i-1}|x_i)$ empleando una red neuronal $p_\phi(x_{i-1}|x_i)$, que se entrena para minimizar la divergencia KL entre ambas distribuciones.

$$\phi^* = \arg\min_\phi \mathbb{E}_{x_i \sim p_i(x_i)} \left[\mathcal{D}_{\text{KL}}\left(p_i(x_{i-1}|x_i)||p_\phi(x_{i-1}|x_i)\right)\right]$$



Solución: Condicionar a x_0 I

Lema

Al condicionar $p_i(x_{i-1}|x_i)$ a x_0, el resultado es una distribución gaussiana:

$$p_i(x_{i-1}|x_i, x_0) = \mathcal{N}\left(x_{i-1}; \mu_i(x_i, x_0, i), \sigma^2(i)\mathbf{I}\right)$$

donde:

$$\mu_i(x_i, x_0, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2}x_0 + \frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{1-\bar{\alpha}_i^2}x_i, \quad \sigma(i)^2 = \frac{1-\bar{\alpha}_{i-1}^2}{1-\bar{\alpha}_i^2}\beta_i^2$$



Solución: Condicionar a x_0 II

Teorema

$$\mathbb{E}_{p_i(x_i)}\left[\mathcal{D}_{KL}\left(p_i(x_{i-1}|x_i)||p_\phi(x_{i-1}|x_i)\right)\right] =$$
$$= \mathbb{E}_{p_{data}(x_0)}\mathbb{E}_{p_i(x_i|x_0)}\left[\mathcal{D}_{KL}\left(p_i(x_{i-1}|x_i, x_0)||p_\phi(x_{i-1}|x_i)\right)\right] + C$$

donde C es una constante independiente de ϕ.

Ejemplo de Reverse Process

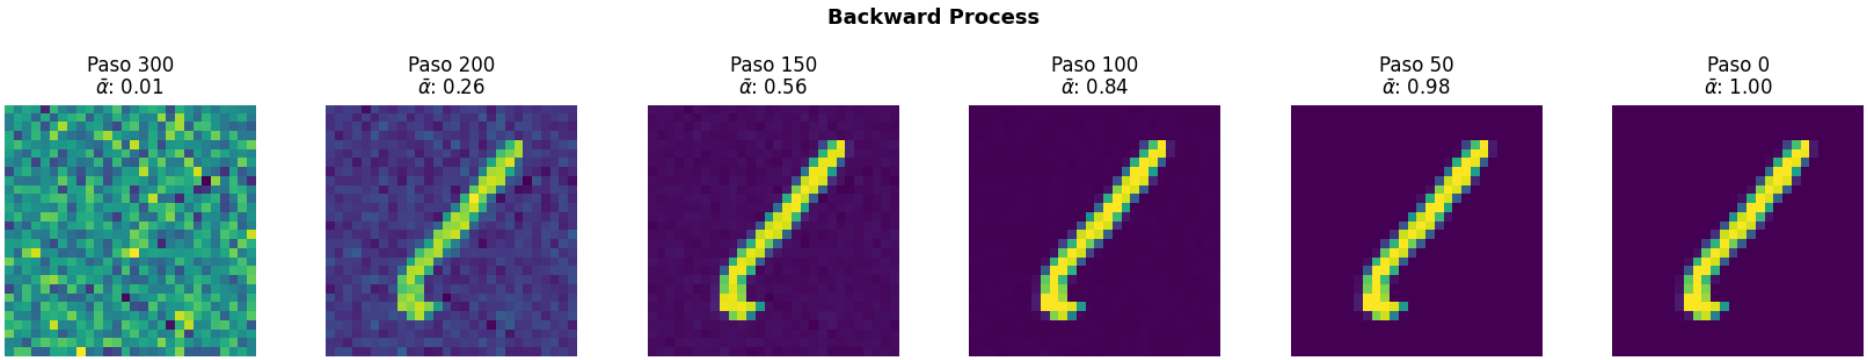


Figura 4: Ejemplo de Reverse Process.

Fuente: Autoría propia [2].

Modelado de Red Neuronal

Siguiendo el lema anterior, se modela $p_\phi(x_{i-1}|x_i)$ como una distribución gaussiana:

$$p_\phi(x_{i-1}|x_i) = \mathcal{N}\left(x_{i-1}; \mu_\phi(x_i, i), \sigma^2(i)\mathbf{I}\right)$$

donde $\sigma^2(i)$ es el valor de la varianza anteriormente descrito y $\mu_\phi(\cdot, i) : \mathbb{R}^d \to \mathbb{R}^d$ es una red neuronal que aproxima $\mu_i(x_i, x_0, i)$.



Función de Pérdida

La función de pérdida a minimizar es la divergencia KL entre las distribuciones gaussianas:

$$\mathcal{L}_{\text{DDPM}}(\phi) = \sum_{i=2}^{L} \mathbb{E}_{p_{\text{data}}(x_0)} \mathbb{E}_{p_i(x_i|x_0)} \left[\mathcal{D}_{\text{KL}} \left(p_i(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i) \right) \right]$$



Función de Pérdida

La función de pérdida a minimizar es la divergencia KL entre las distribuciones gaussianas:

$$\mathcal{L}_{\text{DDPM}}(\phi) = \sum_{i=2}^{L} \mathbb{E}_{p_{\text{data}}(x_0)} \mathbb{E}_{p_i(x_i|x_0)} \left[\mathcal{D}_{\text{KL}} \left(p_i(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i) \right) \right]$$

$$= \sum_{i=2}^{L} \frac{1}{2\sigma^2(i)} \mathbb{E}_{p_{\text{data}}(x_0)} \mathbb{E}_{p_i(x_i|x_0)} \left[\left\| \boldsymbol{\mu}(x_i, x_0, i) - \boldsymbol{\mu}_\phi(x_i, i) \right\|^2 \right] + C$$

donde C es una constante independiente de ϕ.



Monte Carlo como Estimador Insesgado

Al tratarse el estimador de Monte Carlo de un estimador insesgado, se puede reescribir la función de pérdida como:

$$(L-1)\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{p_i(x_i|x_0)}\left[\frac{1}{2\sigma^2(i)}\left\|\boldsymbol{\mu}(x_i,x_0,i)-\boldsymbol{\mu}_\phi(x_i,i)\right\|^2\right]+C$$



Monte Carlo como Estimador Insesgado

Al tratarse el estimador de Monte Carlo de un estimador insesgado, se puede reescribir la función de pérdida como:

$$(L-1)\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{p_i(x_i|x_0)}\left[\frac{1}{2\sigma^2(i)}\left\|\boldsymbol{\mu}(x_i,x_0,i)-\boldsymbol{\mu}_\phi(x_i,i)\right\|^2\right]+C$$

A efectos de entrenamiento, se puede reescribir la función de pérdida como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{p_i(x_i|x_0)}\left[\frac{1}{2\sigma^2(i)}\left\|\boldsymbol{\mu}(x_i,x_0,i)-\boldsymbol{\mu}_\phi(x_i,i)\right\|^2\right]$$



Problema: Desbordamiento

Debido a los valores muy pequeños de $\sigma^2(i)$, la función de pérdida se desborda.

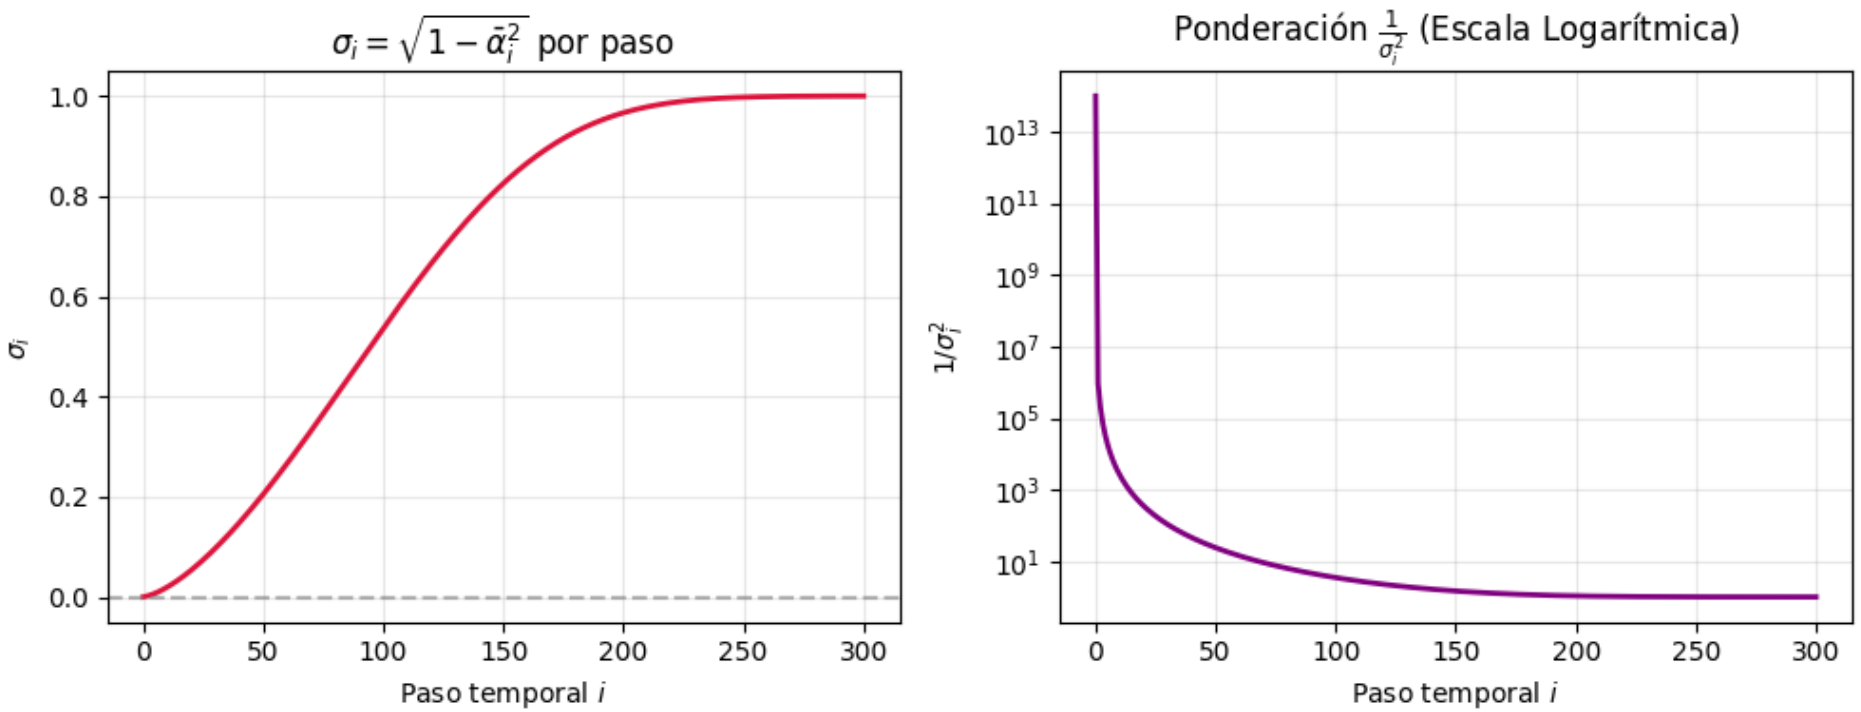


Figura 5: Valores de $\sigma^2(i)$ para un ejemplo de schedule de ruido.

Fuente: Autoría propia [2].

ϵ-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$, se predice $\epsilon_\phi(x_i, i)$, el ruido añadido en el paso i, puesto que:

$$\mu_i(x_i, x_0, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon\right) \implies \mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon_\phi(x_i, i)\right)$$

donde $\bar{\beta}_i^2 + \bar{\alpha}_i^2 = 1$.

[1] Esto no ocurría en el caso de *mean*-prediction.

ϵ-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$, se predice $\epsilon_\phi(x_i, i)$, el ruido añadido en el paso i, puesto que:

$$\mu_i(x_i, x_0, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon\right) \implies \mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon_\phi(x_i, i)\right)$$

donde $\bar{\beta}_i^2 + \bar{\alpha}_i^2 = 1$. La función de pérdida se reescribe como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[w(i)\left\|\epsilon - \epsilon_\phi(x_i, i)\right\|^2\right]$$

donde $w(i)$ es un factor de peso.

[1] Esto no ocurría en el caso de *mean*-prediction.

ϵ-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$, se predice $\epsilon_\phi(x_i, i)$, el ruido añadido en el paso i, puesto que:

$$\mu_i(x_i, x_0, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon\right) \implies \mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon_\phi(x_i, i)\right)$$

donde $\bar{\beta}_i^2 + \bar{\alpha}_i^2 = 1$. La función de pérdida se reescribe como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[w(i)\,\|\epsilon - \epsilon_\phi(x_i, i)\|^2\right]$$

donde $w(i)$ es un factor de peso. Puesto que $\epsilon \sim \mathcal{N}(0, \mathbf{I})$, la diferencia $\epsilon - \epsilon_\phi(x_i, i)$ es de magnitud similar para todos los pasos i, por lo que el factor de peso $w(i)$ puede eliminarse[1], obteniéndose la función de pérdida final:

$$\mathcal{L}_{\text{DDPM}}(\phi) = \mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\|\epsilon - \epsilon_\phi(x_i, i)\|^2\right]$$

[1] Esto no ocurría en el caso de *mean*-prediction.

x_0-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$ o $\epsilon_\phi(x_i, i)$, se predice $x_{0,\phi}(x_i, i)$, el dato original a partir del dato ruidoso en el paso i, puesto que:

$$\mu_{\phi_i}(x_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2} x_{0,\phi}(x_i, i) + \frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{1-\bar{\alpha}_i^2} x_i$$



x_0-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$ o $\epsilon_\phi(x_i, i)$, se predice $x_{0,\phi}(x_i, i)$, el dato original a partir del dato ruidoso en el paso i, puesto que:

$$\mu_{\phi_i}(x_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2} x_{0,\phi}(x_i, i) + \frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{1-\bar{\alpha}_i^2} x_i$$

La función de pérdida se reescribe como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[w(i)\left\|x_0 - x_{0,\phi}(x_i, i)\right\|^2\right]$$

donde $w(i)$ es un factor de peso.



x_0-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$ o $\epsilon_\phi(x_i, i)$, se predice $x_{0,\phi}(x_i, i)$, el dato original a partir del dato ruidoso en el paso i, puesto que:

$$\mu_{\phi_i}(x_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2} x_{0,\phi}(x_i, i) + \frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{1-\bar{\alpha}_i^2} x_i$$

La función de pérdida se reescribe como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[w(i)\left\|x_0 - x_{0,\phi}(x_i, i)\right\|^2\right]$$

donde $w(i)$ es un factor de peso. Puesto que x_0 es de magnitud similar para todos los pasos i, el factor de peso $w(i)$ puede eliminarse, obteniéndose la función de pérdida final:

$$\mathcal{L}_{\text{DDPM}}(\phi) = \mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\left\|x_0 - x_{0,\phi}(x_i, i)\right\|^2\right]$$

x_0-Prediction

En lugar de predecir $\mu_\phi(x_i, i)$ o $\epsilon_\phi(x_i, i)$, se predice $x_{0,\phi}(x_i, i)$, el dato original a partir del dato ruidoso en el paso i, puesto que:

$$\mu_{\phi_i}(x_i, i) = \frac{\bar{\alpha}_{i-1}\beta_i^2}{1-\bar{\alpha}_i^2} x_{0,\phi}(x_i, i) + \frac{\alpha_i(1-\bar{\alpha}_{i-1}^2)}{1-\bar{\alpha}_i^2} x_i$$

La función de pérdida se reescribe como:

$$\mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[w(i)\left\|x_0 - x_{0,\phi}(x_i, i)\right\|^2\right]$$

donde $w(i)$ es un factor de peso. Puesto que x_0 es de magnitud similar para todos los pasos i, el factor de peso $w(i)$ puede eliminarse, obteniéndose la función de pérdida final:

$$\mathcal{L}_{\text{DDPM}}(\phi) = \mathbb{E}_{i\sim\mathcal{U}\{2,\dots,L\}}\mathbb{E}_{p_{\text{data}}(x_0)}\mathbb{E}_{\epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\left\|x_0 - x_{0,\phi}(x_i, i)\right\|^2\right]$$

Índice

1 Introducción

2 Forward Process

3 Reverse Process

4 ELBO de DDPM

5 Sampling



ELBO de DDPM

ELBO de DDPM

El *Evidence Lower Bound* (ELBO) de un DDPM es:

$$\mathcal{L}_{\text{ELBO}}(\phi; x_0) = \mathcal{L}_{\text{prior}}(x_0) + \mathcal{L}_{\text{recon.}}(x_0; \phi) + \mathcal{L}_{\text{diffusion}}(x_0; \phi)$$

$$\mathcal{L}_{\text{prior}}(x_0) = \mathcal{D}_{\text{KL}}\left(p(x_L|x_0) \parallel p_{\text{prior}}(x_L)\right)$$

$$\mathcal{L}_{\text{recon.}}(x_0; \phi) = \mathbb{E}_{p(x_1|x_0)}\left[-\log p_\phi(x_0|x_1)\right]$$

$$\mathcal{L}_{\text{diffusion}}(x_0; \phi) = \sum_{i=2}^{L} \mathbb{E}_{p_i(x_i|x_0)}\left[\mathcal{D}_{\text{KL}}\left(p(x_{i-1}|x_i, x_0) \parallel p_\phi(x_{i-1}|x_i)\right)\right]$$



ELBO de DDPM

Se define:

$$p_\phi(x_0, x_{1:L}) = p_\phi(x_0|x_1)p_\phi(x_1|x_2)\cdots p_\phi(x_{L-1}|x_L)p(x_L)$$



ELBO de DDPM

Se define:

$$p_\phi(x_0, x_{1:L}) = p_\phi(x_0|x_1)p_\phi(x_1|x_2)\cdots p_\phi(x_{L-1}|x_L)p(x_L)$$

$$p_\phi(x_0) = \int p_\phi(x_0, x_{1:L})dx_{1:L}$$

Teorema

$$\log p_\phi(x_0) \geq \mathcal{L}_{ELBO}(\phi; x_0)$$



Índice

1 Introducción

2 Forward Process

3 Reverse Process

4 ELBO de DDPM

5 Sampling



Sampling

Una vez entrenado el modelo, se puede generar un dato original a partir de ruido puro:

1. Se genera un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
2. Se aplica el Reverse Process, obteniéndose $\mathbf{x}_0$.



Sampling

Una vez entrenado el modelo, se puede generar un dato original a partir de ruido puro:

1. Se genera un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
2. Se aplica el Reverse Process, obteniéndose $\mathbf{x}_0$.
   - Si se ha entrenado el modelo para predecir $\mu_\phi(x_i, i)$:

$$x_{i-1} = \mu_\phi(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$



Sampling

Una vez entrenado el modelo, se puede generar un dato original a partir de ruido puro:

1. Se genera un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
2. Se aplica el Reverse Process, obteniéndose $\mathbf{x}_0$.
   - Si se ha entrenado el modelo para predecir $\mu_\phi(x_i, i)$:

$$x_{i-1} = \mu_\phi(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

   - Si se ha entrenado el modelo para predecir $\epsilon_\phi(x_i, i)$:

$$\mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon_\phi(x_i, i)\right)$$



Sampling

Una vez entrenado el modelo, se puede generar un dato original a partir de ruido puro:

1. Se genera un dato ruidoso $\mathbf{x}_L \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$.
2. Se aplica el Reverse Process, obteniéndose $\mathbf{x}_0$.
   - Si se ha entrenado el modelo para predecir $\mu_\phi(x_i, i)$:

$$x_{i-1} = \mu_\phi(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

   - Si se ha entrenado el modelo para predecir $\epsilon_\phi(x_i, i)$:

$$\mu_\phi(x_i, i) = \frac{1}{\alpha_i}\left(x_i - \frac{\beta_i^2}{\bar{\beta}_i}\epsilon_\phi(x_i, i)\right)$$

   - Si se ha entrenado el modelo para predecir $x_{0,\phi}(x_i, i)$:

$$\epsilon_\phi(x_i, i) = \frac{x_i - \bar{\alpha}_i x_{0,\phi}(x_i, i)}{\bar{\beta}_i}$$



Denoise y Re-noise

La predicción de x_{i-1} a partir de x_i cumple:

$$\hat{x}_{i-1} = \bar{\alpha}_{i-1} x_{\phi\times}(x_i, i) + \sqrt{1 - \bar{\alpha}_{i-1}^2 - \sigma^2(i)}\,\epsilon_{\phi\times}(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$



Denoise y Re-noise

La predicción de x_{i-1} a partir de x_i cumple:

$$\hat{x}_{i-1} = \bar{\alpha}_{i-1} x_{\phi^\times}(x_i, i) + \sqrt{1 - \bar{\alpha}_{i-1}^2 - \sigma^2(i)}\,\epsilon_{\phi^\times}(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

Además, $(1 - \bar{\alpha}_{i-1}^2 - \sigma^2(i)) + \sigma^2(i) = 1 - \bar{\alpha}_{i-1}^2$, por lo que se puede entender que el proceso de predicción de x_{i-1} a partir de x_i consiste en:

1. *Denoise*: Se elimina el ruido de x_i para obtener $x_{0,\phi^\times}(x_i, i)$.
2. *Re-noise*: Se añade ruido a $x_{0,\phi^\times}(x_i, i)$ para obtener $\hat{x}_{i-1}$.



Denoise y Re-noise

La predicción de x_{i-1} a partir de x_i cumple:

$$\hat{x}_{i-1} = \bar{\alpha}_{i-1} x_{\phi^\times}(x_i, i) + \sqrt{1 - \bar{\alpha}_{i-1}^2 - \sigma^2(i)}\,\epsilon_{\phi^\times}(x_i, i) + \sigma(i)\epsilon, \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$$

Además, $(1 - \bar{\alpha}_{i-1}^2 - \sigma^2(i)) + \sigma^2(i) = 1 - \bar{\alpha}_{i-1}^2$, por lo que se puede entender que el proceso de predicción de x_{i-1} a partir de x_i consiste en:

1. *Denoise*: Se elimina el ruido de x_i para obtener $x_{0,\phi^\times}(x_i, i)$.
2. *Re-noise*: Se añade ruido a $x_{0,\phi^\times}(x_i, i)$ para obtener $\hat{x}_{i-1}$.

En el paso de *Denoise*, solo se pueden predecir imágenes de *media*, luego produce imágenes borrosas (especialmente en pasos altos).



Baja velocidad de síntesis

Fijado un número de pasos L, la síntesis requiere L pasos de predicción en los que cada uno depende del anterior. Esto provoca $\mathcal{O}(L)$ pasos de predicción, imposibilitando la paralelización de la síntesis.



Baja velocidad de síntesis

Fijado un número de pasos L, la síntesis requiere L pasos de predicción en los que cada uno depende del anterior. Esto provoca $\mathcal{O}(L)$ pasos de predicción, imposibilitando la paralelización de la síntesis.

En nuestra aproximación, $p_\phi(x_{i-1}|x_i)$ es una gaussiana para aproximar $p_i(x_{i-1}|x_i)$, pera esta última no necesariamente es gaussiana (es mezcla ponderada de gaussianas).

- Si $beta_i$ es pequeño, $p_i(x_{i-1}|x_i)$ es unimodal y puede aproximarse bien con una gaussiana.
- Si $beta_i$ es grande, $p_i(x_{i-1}|x_i)$ puede ser multimodal y no puede aproximarse bien con una gaussiana.

Por tanto, se requiere un número grande de pasos L para que β_i sea pequeño y la aproximación sea buena, lo que provoca una baja velocidad de síntesis.



Bibliografía I

[1] Chieh-Hsin Lai et al. *The Principles of Diffusion Models*. 2026. arXiv: 2510.21890 [cs.LG]. URL: https://arxiv.org/abs/2510.21890.

[2] Arturo Olivares Martos. *Implementación de un DDPM para el dataset MNIST*. 2026. URL: https://github.com/arturo-olvrs/DDPM-MNIST (visitado 11-10-2026).

