Capítulo 3.1. y 3.2: Energy-Based Models & Score-Based Models

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

10 de noviembre de 2026



Índice

1. Energy-Based Models
2. Función de Score
3. Langevin Sampling
4. Score-Based Models
5. Sliced SM



Energy-Based Models

Dado un conjunto de datos $\mathcal{D} = \{x_1, x_2, \ldots, x_N\} \subset \mathbb{R}^D$, entrenar directamente $p_\phi : \mathbb{R}^D : \mathbb{R}_0^+$ función de densidad no es sencillo. Por tanto, se emplea una *función de energía* $E_\phi : \mathbb{R}^D \to \mathbb{R}$, que asigna valores bajos de energía a datos reales, y valores altos a datos irreales.



Energy-Based Models

Dado un conjunto de datos $\mathcal{D} = \{x_1, x_2, \ldots, x_N\} \subset \mathbb{R}^D$, entrenar directamente $p_\phi : \mathbb{R}^D : \mathbb{R}_0^+$ función de densidad no es sencillo. Por tanto, se emplea una *función de energía* $E_\phi : \mathbb{R}^D \to \mathbb{R}$, que asigna valores bajos de energía a datos reales, y valores altos a datos irreales.
La función de energía induce una distribución de probabilidad:

$$p_\phi(x) = \frac{\exp(-E_\phi(x))}{Z_\phi}, \quad Z_\phi = \int_{\mathbb{R}^D} \exp(-E_\phi(x))\ dx$$



Entrenamiento: Versión naïve

Buscamos maximizar la log-verosimilitud de los datos:

$$\mathcal{L}(\phi) = \mathbb{E}_{x\sim p_{\text{data}}}[\log p_\phi(x)] = \mathbb{E}_{x\sim p_{\text{data}}}[-E_\phi(x) - \log Z_\phi] =$$
$$= \mathbb{E}_{x\sim p_{\text{data}}}[-E_\phi(x)] - \log Z_\phi$$



Entrenamiento: Versión naïve

Buscamos maximizar la log-verosimilitud de los datos:

$$\mathcal{L}(\phi) = \mathbb{E}_{x\sim p_{\text{data}}}[\log p_\phi(x)] = \mathbb{E}_{x\sim p_{\text{data}}}[-E_\phi(x) - \log Z_\phi] =$$
$$= \mathbb{E}_{x\sim p_{\text{data}}}[-E_\phi(x)] - \log Z_\phi$$

Problema: $\log Z_\phi$ es intractable.



Índice

1 Energy-Based Models

2 Función de Score

3 Langevin Sampling

4 Score-Based Models

5 Sliced SM



Solución: Función de Score

Función de Score

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. La función de score de p es:

$$\begin{aligned} s_p : \quad \mathbb{R}^D &\longrightarrow \mathbb{R}^D \\ x &\longmapsto \nabla_x \log p(x) \end{aligned}$$



Solución: Función de Score

Función de Score

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. La función de score de p es:

$$\begin{aligned} s_p : \quad \mathbb{R}^D &\longrightarrow \mathbb{R}^D \\ x &\longmapsto \nabla_x \log p(x) \end{aligned}$$

$s_p(x)$ apunta en la dirección de mayor probabilidad, y su magnitud indica la rapidez con la que cambia la probabilidad.



Solución: Función de Score

Función de Score

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. La función de score de p es:

$$\begin{aligned} s_p : \quad \mathbb{R}^D &\longrightarrow \mathbb{R}^D \\ x &\longmapsto \nabla_x \log p(x) \end{aligned}$$

$s_p(x)$ apunta en la dirección de mayor probabilidad, y su magnitud indica la rapidez con la que cambia la probabilidad.

Se notará $s(x)$ en vez de $s_p(x)$ cuando no haya ambigüedad.



Ventajas de la Función de Score

- Ventaja Práctica: Muchas funciones de densidad se dan como funciones de densidad no normalizadas $\tilde{p}(x)$, y se normalizan:

$$p(x) = \frac{\tilde{p}(x)}{Z}, \quad Z = \int_{\mathbb{R}^D} \tilde{p}(x)\ dx$$



Ventajas de la Función de Score

- Ventaja Práctica: Muchas funciones de densidad se dan como funciones de densidad no normalizadas $\tilde{p}(x)$, y se normalizan:

$$p(x) = \frac{\tilde{p}(x)}{Z}, \quad Z = \int_{\mathbb{R}^D} \tilde{p}(x)\, dx$$

$$\nabla_x \log p(x) = \nabla_x \log \tilde{p}(x) - \cancelto{0}{\nabla_x \log Z} = \nabla_x \log \tilde{p}(x)$$



Ventajas de la Función de Score

- Ventaja Práctica: Muchas funciones de densidad se dan como funciones de densidad no normalizadas $\tilde{p}(x)$, y se normalizan:

$$p(x) = \frac{\tilde{p}(x)}{Z}, \quad Z = \int_{\mathbb{R}^D} \tilde{p}(x)\, dx$$

$$\nabla_x \log p(x) = \nabla_x \log \tilde{p}(x) - \cancelto{0}{\nabla_x \log Z} = \nabla_x \log \tilde{p}(x)$$

Se evita la intractabilidad de el cálculo de la integral intractable Z.



Ventajas de la Función de Score

- Ventaja Práctica: Muchas funciones de densidad se dan como funciones de densidad no normalizadas $\tilde{p}(x)$, y se normalizan:

$$p(x) = \frac{\tilde{p}(x)}{Z}, \quad Z = \int_{\mathbb{R}^D} \tilde{p}(x)\, dx$$

$$\nabla_x \log p(x) = \nabla_x \log \tilde{p}(x) - \cancelto{0}{\nabla_x \log Z} = \nabla_x \log \tilde{p}(x)$$

Se evita la intractabilidad de el cálculo de la integral intractable Z.

- Ventaja Teórica: Se puede reconstruir $p(x)$ a partir de $s(x)$:

$$\log p(x) = \log p(x_0) + \int_0^1 s(x_0 + t(x - x_0))^t (x - x_0)\, dt \qquad \forall x \in \mathbb{R}^D$$



Ventajas de la Función de Score

- Ventaja Práctica: Muchas funciones de densidad se dan como funciones de densidad no normalizadas $\tilde{p}(x)$, y se normalizan:

$$p(x) = \frac{\tilde{p}(x)}{Z}, \quad Z = \int_{\mathbb{R}^D} \tilde{p}(x)\, dx$$

$$\nabla_x \log p(x) = \nabla_x \log \tilde{p}(x) - \cancelto{0}{\nabla_x \log Z} = \nabla_x \log \tilde{p}(x)$$

Se evita la intractabilidad de el cálculo de la integral intractable Z.

- Ventaja Teórica: Se puede reconstruir $p(x)$ a partir de $s(x)$:

$$\log p(x) = \log p(x_0) + \int_0^1 s(x_0 + t(x - x_0))^t (x - x_0)\, dt \qquad \forall x \in \mathbb{R}^D$$

Se mantiene la misma expresividad.



Entrenamiento de un EBM usando Score Matching

En vez de minimizar $\mathcal{D}_{\mathsf{KL}}(p_{\mathsf{data}} \| p_\phi)$, se minimiza[1] $\mathcal{D}_{\mathsf{F}}(p_{\mathsf{data}} \| p_\phi)$:

$$\begin{aligned}\mathcal{L}_{\mathsf{SM}}(\phi) &= \frac{1}{2}\mathcal{D}_{\mathsf{F}}(p_{\mathsf{data}} \| p_\phi) = \frac{1}{2}\mathbb{E}_{x\sim p_{\mathsf{data}}}[\|s_\phi(x) - s_{\mathsf{data}}(x)\|_2^2] \\ &= \frac{1}{2}\mathbb{E}_{x\sim p_{\mathsf{data}}}[\|\nabla_x \log p_\phi(x) - \nabla_x \log p_{\mathsf{data}}(x)\|_2^2]\end{aligned}$$

[1] No se llegará al mismo resultado

Entrenamiento de un EBM usando Score Matching

En vez de minimizar $\mathcal{D}_{\mathrm{KL}}(p_{\mathrm{data}} \| p_\phi)$, se minimiza[1] $\mathcal{D}_{\mathrm{F}}(p_{\mathrm{data}} \| p_\phi)$:

$$\begin{aligned}\mathcal{L}_{\mathrm{SM}}(\phi) &= \frac{1}{2}\mathcal{D}_{\mathrm{F}}(p_{\mathrm{data}} \| p_\phi) = \frac{1}{2}\mathbb{E}_{x\sim p_{\mathrm{data}}}[\|s_\phi(x) - s_{\mathrm{data}}(x)\|_2^2] \\ &= \frac{1}{2}\mathbb{E}_{x\sim p_{\mathrm{data}}}[\|\nabla_x \log p_\phi(x) - \nabla_x \log p_{\mathrm{data}}(x)\|_2^2] \\ &= \mathbb{E}_{x\sim p_{\mathrm{data}}}\left[-\operatorname{Tr}(\nabla_x^2 E_\phi(x)) + \frac{1}{2}\|\nabla_x E_\phi(x)\|_2^2\right] + C\end{aligned}$$

Problema: $\nabla_x^2 E_\phi(x)$ requiere $\mathcal{O}(D)$ pases de backpropagation, lo que es ineficiente para D grande. Además, minimizar segundas derivadas es más costoso.

[1] No se llegará al mismo resultado

Índice

1 Energy-Based Models

2 Función de Score

3 Langevin Sampling

4 Score-Based Models

5 Sliced SM



Langevin Sampling en Tiempo Discreto

Langevin Sampling en Tiempo Discreto

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo discreto con paso $\eta > 0$ es:

$$x_{n+1} = x_n + \eta \nabla_x \log p(x_n) + \sqrt{2\eta}\, \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \mathbf{I})$$

Si p es la distribución de probabilidad de los datos, entonces $x_n \sim p$ para $n \to \infty$.



Langevin Sampling en Tiempo Discreto

Langevin Sampling en Tiempo Discreto

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo discreto con paso $\eta > 0$ es:

$$x_{n+1} = x_n + \eta \nabla_x \log p(x_n) + \sqrt{2\eta}\, \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \mathbf{I})$$

Si p es la distribución de probabilidad de los datos, entonces $x_n \sim p$ para $n \to \infty$.

La función de score guía el proceso de Langevin hacia regiones de alta probabilidad, mientras que el término de ruido $\sqrt{2\eta}\, \epsilon_n$ permite escapar de mínimos locales.



Langevin Sampling en Tiempo Discreto

Langevin Sampling en Tiempo Discreto

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo discreto con paso $\eta > 0$ es:

$$x_{n+1} = x_n + \eta \nabla_x \log p(x_n) + \sqrt{2\eta}\, \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \mathbf{I})$$

Si p es la distribución de probabilidad de los datos, entonces $x_n \sim p$ para $n \to \infty$.

La función de score guía el proceso de Langevin hacia regiones de alta probabilidad, mientras que el término de ruido $\sqrt{2\eta}\, \epsilon_n$ permite escapar de mínimos locales.

$$x_{n+1} = x_n - \eta \nabla_x E_\phi(x_n) + \sqrt{2\eta}\, \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, \mathbf{I})$$



Langevin Sampling en Tiempo Continuo

Langevin Sampling en Tiempo Continuo

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo continuo es:

$$dx = \nabla_x \log p(x)\ dt + \sqrt{2}\ dW_t$$

donde $W(t)$ es un movimiento Browniano estándar en $\mathbb{R}^D$.

Si p es la distribución de probabilidad de los datos, entonces $x_t \sim p$ para $t \to \infty$.



Langevin Sampling en Tiempo Continuo

Langevin Sampling en Tiempo Continuo

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo continuo es:

$$dx = \nabla_x \log p(x)\ dt + \sqrt{2}\ dW_t$$

donde $W(t)$ es un movimiento Browniano estándar en $\mathbb{R}^D$.

Si p es la distribución de probabilidad de los datos, entonces $x_t \sim p$ para $t \to \infty$.

La función de score guía el proceso de Langevin hacia regiones de alta probabilidad, mientras que el término de ruido $\sqrt{2}\ dW(t)$ permite escapar de mínimos locales.



Langevin Sampling en Tiempo Continuo

Langevin Sampling en Tiempo Continuo

Sea $p : \mathbb{R}^D \to \mathbb{R}_0^+$ una función de densidad. El proceso de Langevin en tiempo continuo es:

$$dx = \nabla_x \log p(x)\ dt + \sqrt{2}\ dW_t$$

donde $W(t)$ es un movimiento Browniano estándar en $\mathbb{R}^D$.

Si p es la distribución de probabilidad de los datos, entonces $x_t \sim p$ para $t \to \infty$.

La función de score guía el proceso de Langevin hacia regiones de alta probabilidad, mientras que el término de ruido $\sqrt{2}\ dW(t)$ permite escapar de mínimos locales.

$$dx = -\nabla_x E_\phi(x)\ dt + \sqrt{2}\ dW(t)$$



Dificultades de Langevin Sampling

Aunque es una técnica útil para generar muestras de una distribución de probabilidad, tiene un principal problema:

Es muy difícil y tarda mucho moverse entre regiones de alta probabilidad (modas) separadas por regiones de baja probabilidad.



Índice

1 Energy-Based Models

2 Función de Score

3 Langevin Sampling

4 Score-Based Models

5 Sliced SM



Motivación de Score-Based Models

Si al muestrear tan solo se necesita la función de score, ¿por qué no entrenar directamente un modelo para aproximar la función de score de los datos, olvidando la función de energía?



Motivación de Score-Based Models

Si al muestrear tan solo se necesita la función de score, ¿por qué no entrenar directamente un modelo para aproximar la función de score de los datos, olvidando la función de energía?

$$s_\phi(x) \approx s_{\text{data}}(x)$$



Motivación de Score-Based Models

Si al muestrear tan solo se necesita la función de score, ¿por qué no entrenar directamente un modelo para aproximar la función de score de los datos, olvidando la función de energía?

$$s_\phi(x) \approx s_{\text{data}}(x)$$

La función de pérdida a minimizar queda:

$$\begin{aligned}\mathcal{L}_{\text{SM}}(\phi) &= \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}}[\|s_\phi(x) - s_{\text{data}}(x)\|_2^2] \\ &= \mathbb{E}_{x\sim p_{\text{data}}}\left[\text{Tr}(\nabla_x s_\phi(x)) + \frac{1}{2}\|s_\phi(x)\|_2^2\right] + C\end{aligned}$$



Intuición de la Función de Pérdida

- Minimizar $\|s_\phi(x)\|_2^2$: Se busca que el modelo prediga un vector de score pequeño para datos reales; es decir, que el modelo prediga que los datos reales son de alta probabilidad.



Intuición de la Función de Pérdida

- Minimizar $\|s_\phi(x)\|_2^2$: Se busca que el modelo prediga un vector de score pequeño para datos reales; es decir, que el modelo prediga que los datos reales son de alta probabilidad.
- Minimizar $\mathrm{Tr}(\nabla_x s_\phi(x))$: Cuando $s_\phi(x) = \nabla_x \log p_{\text{data}}(x)$, en un punto estacionario x^* con $s_\phi(x^*) = 0$, se tiene que:

$$\log p_{\text{data}}(x) \approx \log p_{\text{data}}(x^*) + \frac{1}{2}(x - x^*)^t \nabla_x^2 \log p_{\text{data}}(x^*)(x - x^*)$$



Intuición de la Función de Pérdida

- Minimizar $\|s_\phi(x)\|_2^2$: Se busca que el modelo prediga un vector de score pequeño para datos reales; es decir, que el modelo prediga que los datos reales son de alta probabilidad.
- Minimizar $\mathrm{Tr}(\nabla_x s_\phi(x))$: Cuando $s_\phi(x) = \nabla_x \log p_{\text{data}}(x)$, en un punto estacionario x^* con $s_\phi(x^*) = 0$, se tiene que:

$$\log p_{\text{data}}(x) \approx \log p_{\text{data}}(x^*) + \frac{1}{2}(x - x^*)^t \nabla_x^2 \log p_{\text{data}}(x^*)(x - x^*)$$

Si $\nabla_x^2 \log p_{\text{data}}(x^*)$ es negativa definida, entonces x^* es un máximo local de $\log p_{\text{data}}(x)$, y por tanto un punto de alta probabilidad.



Intuición de la Función de Pérdida

- Minimizar $\|s_\phi(x)\|_2^2$: Se busca que el modelo prediga un vector de score pequeño para datos reales; es decir, que el modelo prediga que los datos reales son de alta probabilidad.
- Minimizar $\mathrm{Tr}(\nabla_x s_\phi(x))$: Cuando $s_\phi(x) = \nabla_x \log p_{\text{data}}(x)$, en un punto estacionario x^* con $s_\phi(x^*) = 0$, se tiene que:

$$\log p_{\text{data}}(x) \approx \log p_{\text{data}}(x^*) + \frac{1}{2}(x - x^*)^t \nabla_x^2 \log p_{\text{data}}(x^*)(x - x^*)$$

Si $\nabla_x^2 \log p_{\text{data}}(x^*)$ es negativa definida, entonces x^* es un máximo local de $\log p_{\text{data}}(x)$, y por tanto un punto de alta probabilidad.
Si es definida negativa, entonces todos los autovalores de $\nabla_x^2 \log p_{\text{data}}(x^*)$ son negativos, y por tanto $\mathrm{Tr}(\nabla_x^2 \log p_{\text{data}}(x^*)) < 0$.
Por tanto, minimizar $\mathrm{Tr}(\nabla_x s_\phi(x))$ fomenta que sea definida negativa, *aunque no garantiza que lo sea (podría tener autovalores positivos aunque la suma de los autovalores sea negativa)*.



Índice

1 Energy-Based Models

2 Función de Score

3 Langevin Sampling

4 Score-Based Models

5 Sliced SM



Sliced Score Matching

Calcular $\mathrm{Tr}(\nabla_x s_\phi(x))$ tiene coste $\mathcal{O}(D)$, lo que es ineficiente para D grande.



Sliced Score Matching

Calcular $\text{Tr}(\nabla_x s_\phi(x))$ tiene coste $\mathcal{O}(D)$, lo que es ineficiente para D grande.

Proposición (Identidad de Hutchinson)

Sean $A \in \mathcal{M}_{D\times D}(\mathbb{R})$ y $s \in \mathbb{R}^D$ fijos. Sea $u \in \mathbb{R}^D$ un vector aleatorio con $\mathbb{E}[u] = 0$ y $\mathbb{E}[uu^t] = \mathbf{I}$. Entonces:

$$\mathbb{E}[u^t A u] = \text{Tr}(A) \qquad \mathbb{E}\left[\left(u^t s\right)^2\right] = s^t s = \|s\|_2^2$$



Sliced Score Matching

Calcular $\mathrm{Tr}(\nabla_x s_\phi(x))$ tiene coste $\mathcal{O}(D)$, lo que es ineficiente para D grande.

Proposición (Identidad de Hutchinson)

Sean $A \in \mathcal{M}_{D\times D}(\mathbb{R})$ y $s \in \mathbb{R}^D$ fijos. Sea $u \in \mathbb{R}^D$ un vector aleatorio con $\mathbb{E}[u] = 0$ y $\mathbb{E}[uu^t] = \mathbf{I}$. Entonces:

$$\mathbb{E}[u^t A u] = \mathrm{Tr}(A) \qquad \mathbb{E}\left[\left(u^t s\right)^2\right] = s^t s = \|s\|_2^2$$

Por ejemplo, $u \rightsquigarrow \mathcal{N}(0, \mathbf{I})$ o $u \rightsquigarrow \text{Rademacher}^D$.



Sliced Score Matching

$$\mathcal{L}_{\text{SSM}}(\phi) = \mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{x\sim p_{\text{data}},u}\left[u^t\left(\nabla_x s_\phi(x)\right)u + \frac{1}{2}\left(u^t s_\phi(x)\right)^2\right]$$



Sliced Score Matching

$$\mathcal{L}_{\text{SSM}}(\phi) = \mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{x\sim p_{\text{data}},u}\left[u^t\left(\nabla_x s_\phi(x)\right)u + \frac{1}{2}\left(u^t s_\phi(x)\right)^2\right]$$

Se usa JVP/VJP y la media muestral (K muestras) como estimador insesgado con varianza $\mathcal{O}\left(1/K\right)$, se obtiene un coste $\mathcal{O}(K)$, que es mucho menor que $\mathcal{O}(D)$ para $K \ll D$.



Sliced Score Matching

$$\mathcal{L}_{\text{SSM}}(\phi) = \mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{x\sim p_{\text{data}},u}\left[u^t\left(\nabla_x s_\phi(x)\right)u + \frac{1}{2}\left(u^t s_\phi(x)\right)^2\right]$$

Se usa JVP/VJP y la media muestral (K muestras) como estimador insesgado con varianza $\mathcal{O}\left(1/K\right)$, se obtiene un coste $\mathcal{O}(K)$, que es mucho menor que $\mathcal{O}(D)$ para $K \ll D$.

¿Sliced? Cada u es una dirección aleatoria, y se proyecta el score en esa dirección. Se repite K veces y se promedia.



Sliced Score Matching

$$\mathcal{L}_{\text{SSM}}(\phi) = \mathcal{L}_{\text{SM}}(\phi) = \mathbb{E}_{x\sim p_{\text{data}},u}\left[u^t\left(\nabla_x s_\phi(x)\right)u + \frac{1}{2}\left(u^t s_\phi(x)\right)^2\right]$$

Se usa JVP/VJP y la media muestral (K muestras) como estimador insesgado con varianza $\mathcal{O}\left(1/K\right)$, se obtiene un coste $\mathcal{O}(K)$, que es mucho menor que $\mathcal{O}(D)$ para $K \ll D$.

¿Sliced? Cada u es una dirección aleatoria, y se proyecta el score en esa dirección. Se repite K veces y se promedia.

En la práctica, $K = 1$ y se deja que el minibatch haga el promedio.



Bibliografía I

[1] Chieh-Hsin Lai et al. *The Principles of Diffusion Models*. 2026. arXiv: 2510.21890 [cs.LG]. URL: https://arxiv.org/abs/2510.21890.

