Capítulo 3.3: Denoising Score Matching

Trabajo de Fin de Grado

Arturo Olivares Martos

Doble Grado en Ingeniería Informática y Matemáticas
Universidad de Granada

10 de noviembre de 2026



Índice

1 Introducción

2 Entrenamiento

3 Por qué "Denoising"



Motivación

El Sliced Score Matching (SSM) está bien, pero...

- Normalmente, p_{data} es nula en la mayoría de los puntos del espacio. Al calcular $\nabla_x \log p_{\text{data}}(x)$, nos encontramos con que la mayoría de los puntos no tienen información útil: no está definido, o es inestable.



Motivación

El Sliced Score Matching (SSM) está bien, pero...

- Normalmente, p_{data} es nula en la mayoría de los puntos del espacio. Al calcular $\nabla_x \log p_{\text{data}}(x)$, nos encontramos con que la mayoría de los puntos no tienen información útil: no está definido, o es inestable. En el muestreo de Langevin, ¡¡no sabemos hacia dónde movernos!!



Motivación

El Sliced Score Matching (SSM) está bien, pero...

- Normalmente, p_{data} es nula en la mayoría de los puntos del espacio. Al calcular $\nabla_x \log p_{\text{data}}(x)$, nos encontramos con que la mayoría de los puntos no tienen información útil: no está definido, o es inestable. En el muestreo de Langevin, ¡¡no sabemos hacia dónde movernos!!
- JVP y VJP, aunque evitan calcular D derivadas parciales, siguen siendo costosos computacionalmente e inducen errores de aproximación.



Solución: Inyección de ruido

En vez de aproximar $s_{\text{data}}(x)$, aproximamos $s_{\tilde{p}}(x)$, donde $\tilde{p}(x)$ es una versión modificada de $p_{\text{data}}(x)$.



Solución: Inyección de ruido

En vez de aproximar $s_{\text{data}}(x)$, aproximamos $s_{\tilde{p}}(x)$, donde $\tilde{p}(x)$ es una versión modificada de $p_{\text{data}}(x)$.

- Fijado un nivel de ruido σ, inyectamos ruido a los datos empleando $p_\sigma(\tilde{x}|x)$.



Solución: Inyección de ruido

En vez de aproximar $s_{\text{data}}(x)$, aproximamos $s_{\tilde{p}}(x)$, donde $\tilde{p}(x)$ es una versión modificada de $p_{\text{data}}(x)$.

- Fijado un nivel de ruido σ, inyectamos ruido a los datos empleando $p_\sigma(\tilde{x}|x)$.
- El modelo $s_\phi(\widetilde{x}, \sigma)$ aproxima $s_{p_\sigma}(\tilde{x})$, el score de la marginal de los datos ruidosos:

$$p_\sigma(\tilde{x}) = \int_{\mathbb{R}^D} p_\sigma(\tilde{x}|x) p_{\text{data}}(x) dx$$



Solución: Inyección de ruido

En vez de aproximar $s_{\text{data}}(x)$, aproximamos $s_{\tilde{p}}(x)$, donde $\tilde{p}(x)$ es una versión modificada de $p_{\text{data}}(x)$.

- Fijado un nivel de ruido σ, inyectamos ruido a los datos empleando $p_\sigma(\tilde{x}|x)$.
- El modelo $s_\phi(\widetilde{x}, \sigma)$ aproxima $s_{p_\sigma}(\tilde{x})$, el score de la marginal de los datos ruidosos:

$$p_\sigma(\tilde{x}) = \int_{\mathbb{R}^D} p_\sigma(\tilde{x}|x) p_{\text{data}}(x) dx$$

- Si $\sigma \approx 0$, $p_\sigma(\tilde{x}) \approx p_{\text{data}}(x)$ y $s_{p_\sigma}(\tilde{x}) \approx s_{\text{data}}(x)$. Por tanto, podremos emplearlo para generar muestras de $p_{\text{data}}(x)$ mediante muestreo de Langevin.



Ventajas de la inyección de ruido

$p_\sigma(\tilde{x})$ es una versión suavizada de $p_{\text{data}}(x)$. Si $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2\mathbf{I})$, entonces:

$$p_\sigma = p_{\text{data}} * \mathcal{N}(0, \sigma^2\mathbf{I})$$



Ventajas de la inyección de ruido

$p_\sigma(\tilde{x})$ es una versión suavizada de $p_{\text{data}}(x)$. Si $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2\mathbf{I})$, entonces:

$$p_\sigma = p_{\text{data}} * \mathcal{N}(0, \sigma^2\mathbf{I})$$

- $p_\sigma(\tilde{x})$ es más estable y está definido en todo el espacio, por lo que $s_{p_\sigma}(\tilde{x})$ también lo está.



Ventajas de la inyección de ruido

$p_\sigma(\tilde{x})$ es una versión suavizada de $p_{\text{data}}(x)$. Si $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2\mathbf{I})$, entonces:

$$p_\sigma = p_{\text{data}} * \mathcal{N}(0, \sigma^2\mathbf{I})$$

- $p_\sigma(\tilde{x})$ es más estable y está definido en todo el espacio, por lo que $s_{p_\sigma}(\tilde{x})$ también lo está.
- Mayor cobertura del espacio de datos, pues es más sencillo para el muestreo de Langevin moverse entre regiones de alta densidad de $p_\sigma(\tilde{x})$.



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:

- Si σ es demasiado grande, $p_\sigma(\tilde{x})$ es demasiado suave y no se parece a $p_{\text{data}}(x)$.
  Es útil para explorar el espacio de datos, pero tan solo aporta estructuras globales de $p_{\text{data}}(x)$.



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:

- Si σ es demasiado grande, $p_\sigma(\tilde{x})$ es demasiado suave y no se parece a $p_{\text{data}}(x)$.
  Es útil para explorar el espacio de datos, pero tan solo aporta estructuras globales de $p_{\text{data}}(x)$.
- Si σ es demasiado pequeño, $p_\sigma(\tilde{x})$ se parece a $p_{\text{data}}(x)$, pero es inestable y no está definido en todo el espacio.
  Proporciona información más detallada sobre la estructura de los datos, pero puede ser difícil de usar en la práctica.



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:

- Si σ es demasiado grande, $p_\sigma(\tilde{x})$ es demasiado suave y no se parece a $p_{\text{data}}(x)$.
  Es útil para explorar el espacio de datos, pero tan solo aporta estructuras globales de $p_{\text{data}}(x)$.
- Si σ es demasiado pequeño, $p_\sigma(\tilde{x})$ se parece a $p_{\text{data}}(x)$, pero es inestable y no está definido en todo el espacio.
  Proporciona información más detallada sobre la estructura de los datos, pero puede ser difícil de usar en la práctica.

¿Necesitamos un único nivel de ruido σ?



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:

- Si σ es demasiado grande, $p_\sigma(\tilde{x})$ es demasiado suave y no se parece a $p_{\text{data}}(x)$.
  Es útil para explorar el espacio de datos, pero tan solo aporta estructuras globales de $p_{\text{data}}(x)$.
- Si σ es demasiado pequeño, $p_\sigma(\tilde{x})$ se parece a $p_{\text{data}}(x)$, pero es inestable y no está definido en todo el espacio.
  Proporciona información más detallada sobre la estructura de los datos, pero puede ser difícil de usar en la práctica.

¿Necesitamos un único nivel de ruido σ? ¡No!



Efectos de la elección de σ

Trade-off entre estabilidad y precisión:

- Si σ es demasiado grande, $p_\sigma(\tilde{x})$ es demasiado suave y no se parece a $p_{\text{data}}(x)$.
  Es útil para explorar el espacio de datos, pero tan solo aporta estructuras globales de $p_{\text{data}}(x)$.
- Si σ es demasiado pequeño, $p_\sigma(\tilde{x})$ se parece a $p_{\text{data}}(x)$, pero es inestable y no está definido en todo el espacio.
  Proporciona información más detallada sobre la estructura de los datos, pero puede ser difícil de usar en la práctica.

¿Necesitamos un único nivel de ruido σ? ¡No!
Pero esos serán los NCSN, tranquilidad...



Índice

1 Introducción

2 Entrenamiento

3 Por qué "Denoising"



Entrenamiento

$$\mathcal{L}_{\mathsf{SM}}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{\tilde{x}\sim p_\sigma(\tilde{x})}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x})\|_2^2]$$



Entrenamiento

$$\mathcal{L}_{\text{SM}}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{\tilde{x}\sim p_\sigma(\tilde{x})}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x})\|_2^2]$$

¡Intractable!



Entrenamiento

$$\mathcal{L}_{SM}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{\tilde{x}\sim p_\sigma(\tilde{x})}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x})\|_2^2]$$

¡Intractable!

Teorema (Equivalencia entre $\mathcal{L}_{DSM}$ y $\mathcal{L}_{SM}$)

Fijado un nivel de ruido σ, se cumple que:

$$\mathcal{L}_{SM}(\phi, \sigma) = \mathcal{L}_{DSM}(\phi, \sigma) + C_\sigma$$

$$\mathcal{L}_{DSM}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{x\sim p_{data}(x), \tilde{x}\sim p_\sigma(\tilde{x}|x)}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x}|x)\|_2^2]$$

Entrenamiento

$$\mathcal{L}_{\text{SM}}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{\tilde{x}\sim p_\sigma(\tilde{x})}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x})\|_2^2]$$

¡Intractable!

Teorema (Equivalencia entre $\mathcal{L}_{\text{DSM}}$ y $\mathcal{L}_{\text{SM}}$)

Fijado un nivel de ruido σ, se cumple que:

$$\mathcal{L}_{SM}(\phi, \sigma) = \mathcal{L}_{DSM}(\phi, \sigma) + C_\sigma$$

$$\mathcal{L}_{DSM}(\phi, \sigma) := \frac{1}{2}\mathbb{E}_{x\sim p_{data}(x), \tilde{x}\sim p_\sigma(\tilde{x}|x)}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x}|x)\|_2^2]$$

El valor óptimo es:

$$s_\phi^*(\tilde{x}, \sigma) = s_{p_\sigma}(\tilde{x}) = \nabla_{\tilde{x}} \log p_\sigma(\tilde{x})$$

Ejemplo: $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2\mathbf{I})$

Un caso muy común es el de inyectar ruido gaussiano isotrópico a los datos:

$$\widetilde{x} = x + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$



Ejemplo: $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2 \mathbf{I})$

Un caso muy común es el de inyectar ruido gaussiano isotrópico a los datos:

$$\widetilde{x} = x + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$s_{p_\sigma}(\tilde{x}|x) = \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}|x) = \frac{x - \tilde{x}}{\sigma^2}$$



Ejemplo: $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2 \mathbf{I})$

Un caso muy común es el de inyectar ruido gaussiano isotrópico a los datos:

$$\widetilde{x} = x + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$s_{p_\sigma}(\tilde{x}|x) = \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}|x) = \frac{x - \tilde{x}}{\sigma^2}$$

$$\begin{aligned}
\mathcal{L}_{\text{DSM}}(\phi, \sigma) &= \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}(x), \tilde{x}\sim p_\sigma(\tilde{x}|x)}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x}|x)\|_2^2] \\
&= \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}(x), \epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\|s_\phi(x + \sigma\epsilon, \sigma) + \frac{\epsilon}{\sigma}\|_2^2\right]
\end{aligned}$$



Ejemplo: $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; x, \sigma^2 \mathbf{I})$

Un caso muy común es el de inyectar ruido gaussiano isotrópico a los datos:

$$\widetilde{x} = x + \sigma\epsilon, \quad \epsilon \sim \mathcal{N}(0, \mathbf{I})$$

$$s_{p_\sigma}(\tilde{x}|x) = \nabla_{\tilde{x}} \log p_\sigma(\tilde{x}|x) = \frac{x - \tilde{x}}{\sigma^2}$$

$$\begin{aligned}\mathcal{L}_{\text{DSM}}(\phi, \sigma) &= \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}(x), \tilde{x}\sim p_\sigma(\tilde{x}|x)}[\|s_\phi(\tilde{x}, \sigma) - s_{p_\sigma}(\tilde{x}|x)\|_2^2] \\ &= \frac{1}{2}\mathbb{E}_{x\sim p_{\text{data}}(x), \epsilon\sim\mathcal{N}(0,\mathbf{I})}\left[\|s_\phi(x + \sigma\epsilon, \sigma) + \frac{\epsilon}{\sigma}\|_2^2\right]\end{aligned}$$

¡Tractable!



Índice

1 Introducción

2 Entrenamiento

3 Por qué "Denoising"



Por qué "Denoising"

Los modelos estudiados se denominan "Denoising" Score Matching, pero hasta ahora tan solo hemos hablado de inyectar ruido a los datos.



Por qué "Denoising"

Los modelos estudiados se denominan "Denoising" Score Matching, pero hasta ahora tan solo hemos hablado de inyectar ruido a los datos.

Lema (Fórmula de Tweedie)

Sea $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; \alpha x, \sigma^2 \mathbf{I})$, *con* α[a] $\in \mathbb{R}^*$. *Entonces:*

$$\alpha \mathbb{E}[x|\tilde{x}] = \tilde{x} + \sigma^2 s_{p_\sigma}(\tilde{x}) = \tilde{x} + \sigma^2 \nabla_{\tilde{x}} \log p_\sigma(\tilde{x})$$

[a] En nuestro caso, $\alpha = 1$.

$E[x|\tilde{x}]$ es el estimador de mínima varianza de x dado $\tilde{x}$, por lo que se puede entender como una forma de "denoising" de $\tilde{x}$.



Por qué "Denoising"

Los modelos estudiados se denominan "Denoising" Score Matching, pero hasta ahora tan solo hemos hablado de inyectar ruido a los datos.

Lema (Fórmula de Tweedie)

Sea $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; \alpha x, \sigma^2 \mathbf{I})$, *con* α[a] $\in \mathbb{R}^*$. *Entonces:*

$$\alpha \mathbb{E}[x|\tilde{x}] = \tilde{x} + \sigma^2 s_{p_\sigma}(\tilde{x}) = \tilde{x} + \sigma^2 \nabla_{\tilde{x}} \log p_\sigma(\tilde{x})$$

[a] En nuestro caso, $\alpha = 1$.

$E[x|\tilde{x}]$ es el estimador de mínima varianza de x dado $\tilde{x}$, por lo que se puede entender como una forma de "denoising" de $\tilde{x}$.

¿Podemos emplearlo de forma directa como *denoiser*?



Por qué "Denoising"

Los modelos estudiados se denominan "Denoising" Score Matching, pero hasta ahora tan solo hemos hablado de inyectar ruido a los datos.

Lema (Fórmula de Tweedie)

Sea $p_\sigma(\tilde{x}|x) = \mathcal{N}(\tilde{x}; \alpha x, \sigma^2 \mathbf{I})$, *con* α[a] $\in \mathbb{R}^*$. *Entonces:*

$$\alpha \mathbb{E}[x|\tilde{x}] = \tilde{x} + \sigma^2 s_{p_\sigma}(\tilde{x}) = \tilde{x} + \sigma^2 \nabla_{\tilde{x}} \log p_\sigma(\tilde{x})$$

[a] En nuestro caso, $\alpha = 1$.

$E[x|\tilde{x}]$ es el estimador de mínima varianza de x dado $\tilde{x}$, por lo que se puede entender como una forma de "denoising" de $\tilde{x}$.

¿Podemos emplearlo de forma directa como *denoiser*?
No. Como en los DDPM, puede ser una distribución multimodal, y el estimador $\mathbb{E}[x|\tilde{x}]$ puede no pertenecer a ninguna de las modas.



Bibliografía I

[1] Chieh-Hsin Lai et al. *The Principles of Diffusion Models*. 2026. arXiv: 2510.21890 [cs.LG]. URL: https://arxiv.org/abs/2510.21890.

